

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه بناب
دانشکده علوم پایه
گروه ریاضی و علوم کامپیوتر

پایان نامه کارشناسی رشته علوم کامپیوتر

حل مسئله مستقیم معادله غیرخطی برگرز با استفاده از شبکه های
عصبی آگاه از فیزیک

استاد راهنما:
دکتر بابک آذرنوید

پژوهشگر:
محمد امیر بابازاد
شماره دانشجویی: ۱۴۰۲۱۳۵۱۰۴

شهریور ۱۴۰۵

کلیه حقوق مادی و معنوی مرتبط با نتایج مطالعات، ابتکارات و نوآوری‌های ناشی از تحقیق موضوع این پایان‌نامه متعلق به دانشگاه بناب است.

تقدیم به

پدر و مادر عزیزم،
که هرچه دارم از دعای خیر و از خودگذشتگی آنهاست،
و به همه آنان که چراغ دانش را در این سرزمین روشن نگه داشته‌اند.

سپاسگزاری

سپاس بی‌کران خداوند یکتا را که توفیق انجام این پژوهش را به این‌جانب عطا فرمود. بر خود لازم می‌دانم از استاد ارجمند، جناب آقای دکتر بابک آذرنوید که راهنمایی این پایان‌نامه را بر عهده داشتند و در تمام مراحل انجام آن، از انتخاب موضوع تا تدوین نهایی، با حوصله و دقت راهنمایم بودند، صمیمانه قدردانی کنم. بی‌شک بدون رهنمودها و حمایت‌های ایشان، این پژوهش به سرانجام نمی‌رسید. همچنین از همه استادان گروه علوم کامپیوتر دانشگاه بناب که در دوران تحصیل از دانش و تجربه آنان بهره‌مند شدم، تشکر و قدردانی می‌کنم. در پایان، از پدر و مادر مهربانم که همواره مشوق و پشتیبان من در مسیر علم‌آموزی بوده‌اند و از همه دوستان و عزیزانی که به هر شکل مرا در انجام این پژوهش یاری رساندند، سپاسگزارم.

محمد امیر بابازاد

شهریور ۱۴۰۵

چکیده

حل عددی معادلات دیفرانسیل جزئی غیرخطی، به‌ویژه معادله برگرز با رفتار پیچیده ناشی از تشکیل امواج شوک و جبهه‌های با گرادیان تند، یکی از چالش‌های بنیادین در دینامیک سیالات و محاسبات علمی است. روش‌های عددی کلاسیک با وجود برخورداری از دقت بالا، وابستگی شدیدی به تولید شبکه محاسباتی دارند و در مواجهه با هندسه‌های پیچیده یا ابعاد بالا با رشد سریع هزینه محاسباتی روبه‌رو می‌شوند. از سوی دیگر، مدل‌های یادگیری عمیق صرفاً داده‌محور نیازمند حجم عظیمی از داده‌های آموزشی تجربی بوده و در غیاب داده‌های متراکم قادر به تضمین سازگاری با اصول فیزیکی حاکم بر سیستم نیستند. چارچوب «شبکه‌های عصبی آگاه از فیزیک» (PINN) به‌عنوان رهیافتی نوین، قوانین دیفرانسیلی فیزیک را مستقیماً در ساختار آموزش شبکه عصبی تلفیق می‌نماید. هدف اصلی این پایان‌نامه، تحلیل نظری، پیاده‌سازی محاسباتی و ارزیابی دقیق این چارچوب در حل مسئله مستقیم معادله غیرخطی برگرز یک‌بعدی و مقایسه نتایج آن با مراجع معتبر علمی است.

در این پژوهش، پس از تشریح مبانی نظری معادلات دیفرانسیل جزئی، روش‌های محاسباتی کلاسیک، یادگیری عمیق و سازوکار مشتق‌گیری خودکار، ساختار مدل زمان‌پیوسته شبکه عصبی آگاه از فیزیک تبیین شده است. در بخش محاسباتی، مدل زمان‌پیوسته با معماری پرسپترون چندلایه در زبان برنامه‌نویسی پایتون و با بهره‌گیری از کتابخانه جکس پیاده‌سازی گردید. آموزش مدل با استفاده از یک راهبرد بهینه‌سازی ترکیبی دومرحله‌ای شامل الگوریتم آدام و روش شبه‌نیوتنی L-BFGS انجام گرفت. به‌منظور سنجش دقیق درستی نتایج، یک حل‌گر مرجع مستقل مبتنی بر روش طیفی فوریه با روش گام‌زنی زمانی نمایی مرتبه چهار (ETDRK4) توسعه داده شد و صحت آن با جواب نیمه‌تحلیلی تبدیل کول-هوپف راستی‌آزمایی گردید.

ارزیابی‌های عددی و مقایسه جامع با نتایج مقاله مرجع رئیسی و همکاران (۲۰۱۹) نشان می‌دهد که شبکه عصبی آگاه از فیزیک قادر است تنها با استفاده از تعداد اندکی نقطه روی شرایط مرزی و اولیه و ارضای باقیمانده فیزیکی روی نقاط هم‌مکانی، میدان پیوسته پاسخ زمانی-مکانی معادله برگرز را با دقت بالا بازسازی نماید و پدیده تشکیل موج شوک را به خوبی ردیابی کند. یافته‌های این پژوهش بیانگر کارایی داده‌ای برجسته این رهیافت بدون نیاز به تولید شبکه محاسباتی و پتانسیل بالای آن در مدل‌سازی رفتارهای غیرخطی است.

کلیدواژه‌ها: شبکه‌های عصبی آگاه از فیزیک، معادله غیرخطی برگرز، مسئله مستقیم، مشتق‌گیری خودکار، روش طیفی فوریه، محاسبات علمی.

فهرست اختصارات

در این پایان نامه به منظور سهولت نگارش و اختصار متن، از کوتاه نوشت های استاندارد زیر استفاده شده است:

علامت اختصاری	شرح فارسی
ANN	شبکه عصبی مصنوعی
BC	شرط مرزی
CPU	واحد پردازش مرکزی
GPU	واحد پردازش گرافیکی
IC	شرط اولیه
L-BFGS	روش شبه نیوتنی با حافظه محدود
MLP	پرسپترون چندلایه
MSE	میانگین مربعات خطا
ODE	معادله دیفرانسیل معمولی
PDE	معادله دیفرانسیل جزئی
PINN	شبکه عصبی آگاه از فیزیک
ReLU	واحد خطی یکسوشده
RK	رانگه-کوتا
SSE	مجموع مربعات خطا

فهرست مطالب

پ	سپاسگزاری
ت	چکیده
ث	فهرست اختصارات
ح	فهرست تصاویر
خ	فهرست جداول
۱	۱ مقدمه و کلیات پژوهش
۳	۱-۱ طرح موضوع پژوهش
۴	۲-۱ بیان مسئله
۴	۳-۱ اهداف پژوهش
۵	۴-۱ پرسش‌های پژوهش
۵	۵-۱ روش‌شناسی پژوهش
۶	۶-۱ ساختار پایان‌نامه
۷	۲ مبانی نظری و پیشینه پژوهش
۷	۱-۲ معادلات دیفرانسیل جزئی
۹	۲-۲ روش‌های عددی کلاسیک
۱۰	۳-۲ شبکه‌های عصبی مصنوعی
۱۲	۴-۲ آموزش شبکه‌های عصبی عمیق
۱۳	۵-۲ مشتق‌گیری خودکار
۱۴	۱-۵-۲ حالت‌های مشتق‌گیری خودکار
۱۵	۲-۵-۲ نقش دوگانه و اختصاصی مشتق‌گیری خودکار در PINN
۱۵	۶-۲ پیشینه پژوهش
۱۶	۷-۲ جمع‌بندی فصل
۱۸	۳ شبکه‌های عصبی آگاه از فیزیک
۱۸	۱-۳ صورت‌بندی کلی مسئله و ایده محوری
۲۰	۲-۳ مدل‌های زمان‌پیوسته برای مسئله مستقیم برگرز
۲۱	۳-۳ مدل‌های زمان‌گسسته
۲۲	۴-۳ ملاحظات عملی در پیاده‌سازی و آموزش
۲۳	۵-۳ جمع‌بندی فصل
۲۴	۴ پیاده‌سازی و ارزیابی نتایج
۲۴	۱-۴ بستر محاسباتی و ابزارهای پیاده‌سازی

۲۵		حل گر مرجع طیفی و اعتبارسنجی آن	۲-۴
۲۶		حل مستقیم معادله برگرز	۳-۴
۲۸		ارزیابی مقایسه‌ای با مقاله مرجع	۴-۴
۲۹		بحث و تحلیل نتایج	۵-۴
۳۰		جمع‌بندی فصل	۶-۴

۳۱	۵ نتیجه‌گیری و پیشنهادها		
۳۱		خلاصه پژوهش	۱-۵
۳۲		یافته‌ها و دستاوردهای کلیدی	۲-۵
۳۲		پیشنهادها برای پژوهش‌های آینده	۳-۵

۳۴	فهرست منابع		
----	--------------------	--	--

۳۶	واژه‌نامه		
----	------------------	--	--

۳۸	پیوست الف: کد پیاده‌سازی محاسباتی		
----	--	--	--

۴۵	فرم ارزیابی پایان‌نامه		
----	-------------------------------	--	--

۴۶	Abstract		
----	-----------------	--	--

فهرست تصاویر

۱-۲	ساختار شماتیک یک شبکه عصبی پرسپترون چندلایه با دو متغیر ورودی، دو لایه پنهان و یک خروجی اسکالر	۱۱
۱-۳	نمودار بلوکی چارچوب شبکه عصبی آگاه از فیزیک: تفکیک خطای داده و خطای فیزیک، تجمیع در تابع هزینه کل و حلقه بهینه‌سازی پارامترها	۱۹
۱-۴	توزیع نقاط آموزشی در مسئله مستقیم معادله برگرز: نقاط داده اولیه و مرزی ($N_u = 200$) و نقاط هم‌مکانی باقیمانده ($N_f = 10000$)	۲۶
۲-۴	تاریخچه کاهش تابع هزینه در مسئله مستقیم: همگرایی مرحله اول با الگوریتم آدام و اصلاح نهایی با روش شبه‌نیوتنی L-BFGS	۲۷
۳-۴	مقایسه پروفیل‌های زمانی حل دقیق مرجع و پیش‌بینی شبکه آگاه از فیزیک در سه لحظه $t = 0.25, 0.5, 0.75$	۲۸
۴-۴	نقشه توزیع خطای قدرمطلق $ u_{\text{ref}} - u_{\text{PINN}} $ در دامنه زمانی-مکانی در مسئله مستقیم	۲۸

فهرست جداول

۱-۲	مقایسه ویژگی‌های روش‌های عددی کلاسیک در حل معادلات دیفرانسیل جزئی	۱۰
۲-۲	توابع فعال‌ساز متداول در شبکه‌های عصبی عمیق	۱۱
۱-۳	مقایسه تطبیقی مدل‌های زمان‌پیوسته و زمان‌گسسته در چارچوب شبکه‌های آگاه از فیزیک	۲۲
۱-۴	تنظیمات ساختاری و پارامترهای آموزش مدل زمان‌پیوسته در مسئله مستقیم	۲۷
۲-۴	مقایسه تطبیقی مشخصات و نتایج حل مستقیم معادله برگرز با مقاله مرجع رئیسی و همکاران (۲۰۱۹)	۲۹

فصل ۱

مقدمه و کلیات پژوهش

بسیاری از پدیده‌های بنیادی در علوم پایه و مهندسی، از جمله دینامیک سیالات، انتقال حرارت، مکانیک کوانتومی، انتشار امواج و فرایندهای بیوفیزیکی، در قالب معادلات دیفرانسیل جزئی^۱ مدل‌سازی می‌شوند. از این رو، ارائه روش‌های دقیق، کارآمد و محاسبات‌پذیر برای تحلیل و حل این معادلات همواره یکی از ارکان اصلی در حوزه محاسبات علمی بوده است. در دهه‌های اخیر، پیشرفت‌های شگرف در حوزه یادگیری عمیق^۲ تحولات بنیادینی را در پردازش تصویر، پردازش زبان طبیعی و علوم داده رقم زده است.

با این وجود، به‌کارگیری مستقیم مدل‌های یادگیری عمیق و صرفاً داده‌محور (که به‌عنوان جعبه سیاه^۳ عمل نموده و صرفاً همبستگی‌های آماری میان ورودی و خروجی را فرا می‌گیرند) در مسائل مهندسی و علوم فیزیکی با چالش‌های ساختاری مهمی روبه‌روست. در این گونه مسائل، مفهوم «داده‌های برچسب‌دار» به معنای اندازه‌گیری‌های تجربی از کمیت‌های میدان فیزیکی (نظیر سرعت سیال، توزیع فشار، دما یا غلظت گونه‌های شیمیایی) در نقاط مختلف مکانی و لحظات زمانی است. در بسیاری از سامانه‌های واقعی مهندسی – نظیر بررسی جریان سیال درون محفظه احتراق موتورهای جت، مخازن هیدروکربوری در اعماق زمین، رآکتورهای همجوشی هسته‌ای یا جریان خون درون رگ‌های زیستی – نصب حسگرهای متعدد و ثبت داده‌های پیوسته و متراکم، به دلایلی چون هزینه‌های گزاف آزمایشگاهی، شرایط محیطی خشن یا غیرقابل‌دسترس بودن هندسی، عملاً ناممکن یا بسیار محدود است. بنابراین، مشاهدات موجود همواره به‌صورت تنک، پراکنده و همراه با خطای اندازه‌گیری هستند. در چنین شرایط کم‌داده‌ای، یک شبکه عصبی فاقد درک از قوانین حاکم،

^۱Partial Differential Equation (PDE)

^۲Deep Learning

^۳Black Box

به شدت مستعد بیش‌برازش^۴ بر روی نمونه‌های اندک بوده و در مناطقی که فاقد داده آموزشی است (نواحی برون‌یابی)، ممکن است پیش‌بینی‌هایی کاملاً متناقض با بدیهیات فیزیک (مانند نقض قانون بقای جرم، پیش‌بینی مقادیر دمای منفی ناممکن، یا نقض شرایط مرزی سامانه) تولید نماید.

به‌منظور غلبه بر این محدودیت‌ها، ادغام دانش فیزیکی حاکم بر سیستم با ساختارهای یادگیری ماشین، رویکرد نوینی را تحت عنوان «شبکه‌های عصبی آگاه از فیزیک»^۵ پدید آورده است. این چارچوب توسط رئیسی و همکارانش در سال ۲۰۱۹ معرفی شد [۱] و با استقبال گسترده جامعه علمی در مرز مشترک هوش مصنوعی و محاسبات علمی روبه‌رو گردید. در این رهیافت، معادله دیفرانسیل حاکم به‌همراه شرایط مرزی و اولیه مستقیماً درون تابع هزینه مدل لحاظ می‌شود و شبکه به‌جای اتکای صرف به داده‌های اندازه‌گیری‌شده متراکم، قوانین فیزیک را در کل دامنه ارضا می‌نماید. این امر به شبکه امکان می‌دهد تا به عنوان یک حل‌گر عددی بدون شبکه محاسباتی عمل کند.

در این پایان‌نامه، چارچوب شبکه‌های عصبی آگاه از فیزیک برای حل مسئله مستقیم (محاسبه و بازسازی میدان پاسخ زمانی-مکانی) در معادله دیفرانسیل جزئی غیرخطی برگرز^۶ مورد ارزیابی قرار می‌گیرد. معادله برگرز مدلی پایه‌ای در دینامیک سیالات و جریان ترافیک است که پدیده تشکیل «موج شوک»^۷ و ایجاد «جبهه‌های با شیب بسیار تند»^۸ را توصیف می‌کند. در فیزیک، موج شوک به ناحیه‌ای بسیار باریک و فشرده گفته می‌شود که در آن مشخصات سیال (نظیر سرعت یا فشار) در فاصله مکانی بسیار کوتاهی دچار افت یا جهش ناگهانی و شدید می‌شوند (مانند پدیده شکستن امواج در ساحل یا متراکم شدن ناگهانی خودروها در ترافیک). از آن‌جا که توابع پیوسته و شبکه‌های عصبی استاندارد در تقریب‌زدن این‌گونه رفتارهای نوک‌تیز و شیب‌های تند با دشواری‌های زیادی روبه‌رو هستند، معادله برگرز به یک مسئله معیار و چالش‌برانگیز استاندارد برای ارزیابی دقت روش‌های عددی و یادگیری ماشین تبدیل شده است.

علاوه بر تحلیل نظری، پیاده‌سازی محاسباتی مدل زمان‌پیوسته با زبان برنامه‌نویسی پایتون و کتابخانه جکس^۹ صورت گرفته است. به‌منظور سنجش دقیق درستی نتایج شبکه عصبی، نیازمند یک راهکار مرجع با دقت بسیار بالا بودیم. از این رو، یک «حل‌گر

⁴Overfitting

⁵Physics-Informed Neural Network (PINN)

⁶Burgers Equation

⁷Shock Wave

⁸Steep Fronts / Steep Gradients

⁹JAX

طیفی فوریه»^{۱۰} مستقل توسعه داده شد. روش طیفی فوریه، یک روش عددی کلاسیک و با دقت فوق‌العاده بالاست که جواب معادله دیفرانسیل را به‌جای تکه‌تکه کردن دامنه با نقاط گسسته، به‌صورت مجموعه‌ای از امواج سینوسی و کسینوسی هموار تقریب می‌زند و خطای محاسباتی آن نزدیک به صفر است. در این پایان‌نامه، خروجی این حل‌گر کلاسیک دقیق صرفاً به‌عنوان «پاسخ مرجع و خط‌کش آزمون» مورد استفاده قرار گرفته تا دقت و خطای پیش‌بینی شبکه عصبی آگاه از فیزیک با آن سنجیده شود. همچنین نتایج حاصل با مقاله مرجع معتبر رئیسی و همکاران (۲۰۱۹) مورد مقایسه و ارزیابی تطبیقی قرار گرفته است.

۱-۱ طرح موضوع پژوهش

موضوع محوری این پایان‌نامه «حل مسئله مستقیم معادله غیرخطی برگرز با استفاده از شبکه‌های عصبی آگاه از فیزیک» است. در مسئله مستقیم^{۱۱}، ساختار و کلیه ضرایب فیزیکی معادله دیفرانسیل به‌همراه شرایط مرزی و اولیه به‌طور کامل مشخص بوده و هدف اصلی، تعیین توزیع مکانی-زمانی متغیر مجهول میدان پاسخ $u(t, x)$ با حداقل داده‌های اولیه و مرزی و بدون نیاز به تولید شبکه محاسباتی گسسته است. رکن اساسی و موتور محرک محاسباتی در این چارچوب، بهره‌گیری از سازوکار «مشتق‌گیری خودکار»^{۱۲} است. در روش‌های محاسباتی سنتی، محاسبه مشتقات مکانی و زمانی معادلات دیفرانسیل مستلزم ایجاد شبکه محاسباتی و استفاده از تقریب‌های تفاضل محدود بود که با خطای برش و ناپایداری‌های ناشی از گام گسسته‌سازی همراه است. در مقابل، مشتق‌گیری خودکار تکنیکی بنیادین در علوم داده است که با بهره‌گیری از گراف محاسباتی برنامه و اعمال نظام‌مند قاعده زنجیره‌ای ریاضی، مشتقات جزئی خروجی شبکه نسبت به ورودی‌های فضا و زمان (u_t, u_x, u_{xx}) را با دقت تحلیلی و تا حد خطای ممیز شناور ماشین ارزیابی می‌کند. این قابلیت به مدل اجازه می‌دهد که بدون نیاز به شبکه‌بندی دامنه، باقیمانده فیزیکی معادله را در هر نقطه دلخواه محاسبه نموده و شبکه عصبی را وادار سازد که قوانین بقا و فیزیک حاکم را در سراسر دامنه پیوسته ارضا کند. مبانی نظری و سازوکار مشتق‌گیری خودکار به تفصیل در بخش ۲-۵ تشریح خواهد شد.

¹⁰Fourier Spectral Method

¹¹Forward Problem

¹²Automatic Differentiation

۲-۱ بیان مسئله

روش‌های عددی کلاسیک نظیر روش تفاضل‌های محدود^{۱۳} [۱۶]، روش اجزای محدود^{۱۴} [۱۷] و روش‌های طیفی^{۱۵} [۲۱] طی چندین دهه ابزارهای استوار و تثبیت‌شده در حل معادلات دیفرانسیل جزئی بوده‌اند. با این حال، این روش‌ها به تولید شبکه محاسباتی وابستگی شدیدی دارند و در مسائل با ابعاد بالا، با پدیده نفرین ابعاد^{۱۶} و رشد نمایی هزینه محاسباتی روبه‌رو می‌شوند. علاوه بر این، در مسائلی که شرایط هندسی نامنظم یا داده‌های مرزی پیچیده وجود دارد، اعمال روش‌های کلاسیک با دشواری‌های تکنیکی همراه است.

در نقطه مقابل، شبکه‌های عصبی استاندارد اگرچه از قابلیت بالایی در برازش توابع غیرخطی برخوردارند، اما در صورت عدم برخورداری از قیدهای ساختاری، به حجم بسیار زیادی از داده‌های آموزشی نیاز داشته و خروجی آن‌ها در مناطقی که فاقد داده آموزشی است، ممکن است دچار خطای برون‌یابی شدید و نقض آشکار قوانین فیزیکی گردد. مسئله اصلی این پژوهش را می‌توان در این پرسش خلاصه کرد: چگونه می‌توان با تلفیق ساختار ریاضی معادله دیفرانسیل جزئی برگرز در فرایند آموزش شبکه‌های عصبی عمیق، یک ساختار محاسباتی کارآمد ایجاد کرد که بدون نیاز به شبکه‌بندی محاسباتی و صرفاً با اتکا بر داده‌های مرزی-اولیه محدود و ارضای قید باقیمانده فیزیکی، میدان پیوسته پاسخ را با دقت بالا بازسازی کند و پدیده تشکیل موج شوک را با حداقل خطای عددی به دام اندازد؟ چارچوب شبکه‌های عصبی آگاه از فیزیک [۱] پاسخی ساختاریافته به این نیاز محاسباتی ارائه می‌دهد.

۳-۱ اهداف پژوهش

هدف کلی این پایان‌نامه، تحلیل مبانی نظری، پیاده‌سازی الگوریتمی و ارزیابی تجربی چارچوب شبکه‌های عصبی آگاه از فیزیک در حل مسئله مستقیم معادله غیرخطی برگرز و مقایسه جامع نتایج با مراجع معتبر علمی است. اهداف تفصیلی پژوهش عبارت‌اند از:

۱. بررسی و تدوین مبانی نظری معادلات دیفرانسیل جزئی، روش‌های عددی کلاسیک، شبکه‌های عصبی پیش‌خور، روش‌های بهینه‌سازی و تکنیک‌های مشتق‌گیری

¹³Finite Difference Method

¹⁴Finite Element Method

¹⁵Spectral Methods

¹⁶Curse of Dimensionality

خودکار،

۲. تحلیل ساختار مدل زمان‌پیوسته شبکه‌های آگاه از فیزیک و فرمول‌بندی تابع هزینه ترکیبی بر پایه باقیمانده معادله برگرز،
۳. طراحی و توسعه یک حل‌گر مرجع طیفی مستقل بر پایه تبدیل فوریه برای معادله غیرخطی برگرز به منظور ایجاد معیار ارزیابی دقیق،
۴. پیاده‌سازی محاسباتی مدل زمان‌پیوسته برای حل مستقیم معادله برگرز با استفاده از کتابخانه جکس و الگوریتم بهینه‌سازی ترکیبی آدام و L-BFGS،
۵. ارزیابی خطای تقریب میدان پاسخ در مقایسه با حل‌گر مرجع طیفی و تحلیل مقایسه‌ای نتایج با مقاله معتبر مرجع رئیسی و همکاران (۲۰۱۹).

۴-۱ پرسش‌های پژوهش

این پژوهش در صدد پاسخ‌گویی به پرسش‌های علمی زیر است:

۱. آیا یک شبکه عصبی با ساختار استاندارد قادر است تنها با اتکا بر داده‌های مرزی-اولیه محدود و باقیمانده معادله، پاسخ معادله دیفرانسیل جزئی غیرخطی برگرز را در کل دامنه زمانی-مکانی بدون تولید شبکه محاسباتی تقریب بزند؟
۲. فرایند مشتق‌گیری خودکار چگونه باقیمانده فیزیکی معادله برگرز را در ساختار تابع هزینه مدل تلفیق می‌نماید؟
۳. خطای عددی حاصل از شبکه عصبی آگاه از فیزیک در مقایسه با روش مرجع طیفی فوریه چگونه توزیع می‌شود و رفتار خطا در حوالی جبهه شوک به چه صورت است؟
۴. الگوریتم بهینه‌سازی ترکیبی دو مرحله‌ای (آدام و L-BFGS) چه نقشی در سرعت و دقت همگرایی مدل ایفا می‌کند؟
۵. عملکرد و دقت مدل پیاده‌سازی شده در مقایسه با نتایج گزارش شده در مقاله معتبر مرجع [۱] چگونه ارزیابی می‌شود؟

۵-۱ روش‌شناسی پژوهش

روش‌شناسی به کار رفته در این پایان‌نامه مبتنی بر تلفیق مطالعات تحلیلی-نظری و پیاده‌سازی‌های محاسباتی-تجربی است:

در گام نخست، پیشینه پژوهش و منابع معتبر علمی در حوزه‌های معادلات دیفرانسیل جزئی [۱۸]، روش‌های تفاضل محدود [۱۶]، اجزای محدود [۱۷]، روش‌های

طیفی [۲۱]، یادگیری عمیق [۱۱] و مشتق‌گیری خودکار [۱۵] مورد بررسی و تحلیل جامع قرار گرفت و مبانی نظری شبکه باقیمانده و توابع هزینه تلفیقی استخراج شد. در گام دوم، معادله برگرز یک‌بعدی با شرایط اولیه سینوسی و شرایط مرزی همگن به دلیل رفتار موج شوک غیرخطی به عنوان مسئله آزمون انتخاب شد. برای ایجاد حل دقیق، یک حل‌گر مرجع طیفی فوریه با روش گام‌زنی زمانی مرتبه چهار نمایی (ETDRK4) توسعه یافت و صحت آن با جواب نیمه‌تحلیلی کول-هوپف [۱۹] راستی‌آزمایی گردید.

در گام سوم، مدل زمان‌پیوسته شبکه عصبی آگاه از فیزیک با استفاده از معماری پرسپترون چندلایه و بهینه‌سازی ترکیبی دومرحله‌ای (آدام و سپس L-BFGS) در زبان پایتون با کتابخانه محاسباتی جکس پیاده‌سازی شد. در گام چهارم، آزمایش‌های عددی حل مسئله مستقیم اجرا شده و معیارهای کمی نظیر خطای نسبی در نرم L_2 ، توزیع مکانی-زمانی خطا و تاریخچه همگرایی توابع هزینه با داده‌های حل مرجع و مقاله مرجع رئیسی و همکاران (۲۰۱۹) مورد مقایسه و ارزیابی قرار گرفت.

۶-۱ ساختار پایان‌نامه

فصول این پایان‌نامه به صورت زیر تدوین شده است:

- **فصل دوم (مبانی نظری و پیشینه پژوهش):** مروری بر مفاهیم پایه‌ای معادلات دیفرانسیل جزئی، روش‌های عددی کلاسیک، یادگیری عمیق، مشتق‌گیری خودکار و بررسی تاریخی پژوهش‌های پیشین در یادگیری ماشین آگاه از فیزیک.
- **فصل سوم (شبکه‌های عصبی آگاه از فیزیک):** تشریح ریاضی و ساختاری چارچوب شبکه‌های آگاه از فیزیک، فرمول‌بندی مدل زمان‌پیوسته برای مسئله مستقیم معادله برگرز، ساختار تابع هزینه ترکیبی و نکات عملی در آموزش شبکه.
- **فصل چهارم (پیاده‌سازی و ارزیابی نتایج):** ارائه جزئیات پیاده‌سازی حل‌گر مرجع طیفی، تحلیل نتایج حل مستقیم معادله برگرز، ارزیابی دقت و مقایسه جامع یافته‌ها با مقاله معتبر مرجع.
- **فصل پنجم (نتیجه‌گیری و پیشنهادها):** جمع‌بندی دستاوردهای پژوهش، تبیین محدودیت‌های موجود و ارائه چشم‌اندازها و پیشنهادهایی برای پژوهش‌های آتی.

فصل ۲

مبانی نظری و پیشینه پژوهش

هدف این فصل، تبیین و تشریح مفاهیم پایه‌ای است که چارچوب شبکه‌های عصبی آگاه از فیزیک بر مبنای آن‌ها شکل گرفته است. این مفاهیم به‌گونه‌ای خودخوان و پیوسته تدوین شده‌اند تا خواننده بدون نیاز به دانش پیشین عمیق، مبانی محاسبات علمی و یادگیری ماشین را درک نماید. در ابتدا، تعاریف و ویژگی‌های کلی معادلات دیفرانسیل جزئی به‌همراه مثال‌های کلاسیک فیزیکی ارائه می‌گردد و سپس روش‌های عددی کلاسیک حل این معادلات و محدودیت‌های آن‌ها بررسی می‌شوند. در ادامه، ساختار شبکه‌های عصبی مصنوعی، الگوریتم‌های آموزش و بهینه‌سازی و تکنیک مشتق‌گیری خودکار تشریح می‌گردند. در بخش پایانی فصل، پیشینه مطالعات و سیر تحول روش‌ها در حوزه ترکیب یادگیری ماشین با اصول فیزیکی مرور می‌شود تا جایگاه پژوهش حاضر مشخص گردد.

۱-۲ معادلات دیفرانسیل جزئی

معادله دیفرانسیل جزئی، رابطه‌ای ریاضی میان یک تابع مجهول چندمتغیره و مشتقات جزئی آن نسبت به متغیرهای مستقل فضا و زمان است. در دنیای فیزیکی، این معادلات نحوه تغییر و تکامل یک کمیت پیوسته (نظیر سرعت سیال، فشار، توزیع حرارت یا پتانسیل الکتریکی) را در طول زمان و مکان بیان می‌کنند. صورت عمومی یک معادله دیفرانسیل جزئی برای تابع مجهول $u(x)$ به فرم زیر بیان می‌شود:

$$F(x, u, Du, D^2u, \dots, D^k u) = 0 \quad (1-2)$$

که در آن $x = (x_1, \dots, x_d, t) \in \mathbb{R}^{d+1}$ بردار متغیرهای مستقل مکانی و زمانی، Du نمایانگر گرادیان یا مجموعه مشتقات جزئی مرتبه اول، D^2u ماتریس هشین یا مشتقات جزئی مرتبه دوم و $D^k u$ مشتقات جزئی مرتبه k ام هستند. بالاترین مرتبه مشتق موجود در رابطه را مرتبه معادله می‌نامند. چنانچه عملگر F نسبت به متغیر u و کلیه مشتقات آن خطی باشد، معادله خطی و در غیر این صورت، غیرخطی^۱ نامیده می‌شود [۱۸]. معادلات غیرخطی به دلیل پدیده‌هایی نظیر اندرکنش امواج و ایجاد ناپیوستگی، از پیچیدگی تحلیلی بالایی برخوردارند.

برای تعیین جواب یکتا و فیزیکی از میان بی‌شمار جواب‌های ریاضی ممکن، مسئله باید همراه با شرایط مرزی^۲ و شرایط اولیه^۳ فرمول‌بندی شود. شرط اولیه حالت سیستم را در لحظه آغازین $t = 0$ مشخص نموده و شرایط مرزی نحوه برهم‌کنش سیستم با مرزهای دامنه مکانی $\partial\Omega$ را تعیین می‌کنند. بر اساس تعریف هادامارد، مسئله‌ای که دارای جواب یکتا باشد و جواب آن نسبت به داده‌های اولیه و مرزی پیوسته و پایدار بماند، یک مسئله خوش‌وضع^۴ نامیده می‌شود.

در محاسبات علمی، برخی معادلات به دلیل تبیین پدیده‌های بنیادین، به‌عنوان مسائل معیار شناخته می‌شوند:

معادله گرما. این معادله ساده‌ترین نمونه از معادلات سهموی است که انتقال و پخش حرارت را در یک محیط توصیف می‌کند. فرم یک‌بعدی آن عبارت است از:

$$u_t = \alpha u_{xx} \quad (۲-۲)$$

که در آن $u(t, x)$ بیانگر دما، u_t نرخ تغییرات زمانی، u_{xx} انحنای مکانی توزیع دما و $\alpha > 0$ ضریب پخش حرارتی است. این معادله نشان می‌دهد که گرما همواره از نقاط با دمای بالاتر به نقاط سردتر جریان می‌یابد.

معادله برگرز. معادله برگرز^۵ مدلی ساده‌شده از معادلات حاکم بر دینامیک سیالات و جریان ترافیک است [۱۹]. صورت استاندارد معادله برگرز با لزجت به فرم زیر نوشته می‌شود:

$$u_t + uu_x - \nu u_{xx} = 0 \quad (۳-۲)$$

¹Nonlinear

²Boundary Conditions

³Initial Conditions

⁴Well-posed Problem

⁵Burgers Equation

که در آن $\nu > 0$ ضریب لزجت سینماتیکی است. این معادله تبلور رقابت دو پدیده متضاد در طبیعت است: جمله غیرخطی uu_x نمایانگر انتقال (همرفت) است که تمایل به تیز کردن پروفیل موج و ایجاد جبهه شوک دارد، در حالی که جمله νu_{xx} اثر پخشی داشته و با ایجاد اصطکاک به هموارسازی گرادیان‌ها می‌انجامد. تعامل این دو جمله، به‌ویژه در مقادیر بسیار کوچک ν ، منجر به پدیدار شدن جبهه‌های شیب‌دار تند می‌شود که چالشی جدی برای روش‌های محاسباتی است.

معادله غیرخطی شرودینگر. این معادله در اپتیک غیرخطی، فیزیک پلاسما و مکانیک کوانتومی کاربرد دارد و در مقاله مرجع [۱] نیز به‌عنوان یکی از مسائل آزمون بررسی گردیده است.

۲-۲ روش‌های عددی کلاسیک

معادلات دیفرانسیل جزئی غیرخطی در اغلب موارد فاقد جواب تحلیلی بسته هستند. از این رو، روش‌های عددی نقشی محوری در تحلیل سامانه‌های مهندسی ایفا می‌کنند. اساس کار این روش‌ها، گسسته‌سازی دامنه پیوسته با تولید یک شبکه محاسباتی و تبدیل معادله دیفرانسیل به یک دستگاه معادلات جبری متناهی است. سه رویکرد اصلی عبارت‌اند از:

روش تفاضل‌های محدود. در روش تفاضل‌های محدود^۶، دامنه پیوسته با شبکه‌ای منظم از نقاط جایگزین شده و مشتقات جزئی با استفاده از بسط تیلور پیرامون نقاط همسایه تقریب زده می‌شوند [۱۶]:

$$u_{xx}(x_i) \approx \frac{u_{i+1} - 2u_i + u_{i-1}}{(\Delta x)^2} \quad (۴-۲)$$

که در آن Δx طول گام گسسته‌سازی است. مزیت عمده این روش، سادگی مفاهیم و سهولت پیاده‌سازی است، اما در مواجهه با هندسه‌های پیچیده، کارایی آن به شدت کاهش می‌یابد.

روش اجزای محدود. در روش اجزای محدود^۷، دامنه مکانی به زیردامنه‌های کوچکی به نام المان تقسیم می‌گردد و جواب بر حسب توابع پایه چندجمله‌ای موضعی بسط داده می‌شود [۱۷]. انعطاف‌پذیری بالا در مدیریت هندسه‌های نامنظم، این روش را به استاندارد مهندسی بدل ساخته است، هرچند تولید شبکه محاسباتی و هزینه الگوریتمی

^۶Finite Difference Method

^۷Finite Element Method

جدول ۲-۱: مقایسه ویژگی‌های روش‌های عددی کلاسیک در حل معادلات دیفرانسیل جزئی

روش محاسباتی	ایده بنیادین	مزیت اصلی	محدودیت اصلی
تفاضل‌های محدود	تقریب موضعی مشتقات روی شبکه ساخت‌یافته	سادگی الگوریتمی و پیاده‌سازی	ناتوانی در هندسه‌های نامنظم
اجزای محدود	فرمول‌بندی ضعیف روی المان‌های نامنظم	انعطاف‌پذیری هندسی بالا	هزینه بالای تولید شبکه و محاسبات
روش‌های طیفی	بسط جواب بر حسب توابع پایه سراسری	نرخ همگرایی (دقت بسیار بالا)	محدود به هندسه‌های ساده و شرایط هموار

آن بالاست.

روش‌های طیفی. در روش‌های طیفی^۸، تابع جواب به صورت ترکیبی خطی از توابع پایه متعامد سراسری (مانند چندجمله‌ای‌های چبیشف یا توابع مثلثاتی فوریه) تقریب زده می‌شود [۲۱]. مزیت برجسته این روش‌ها، نرخ همگرایی نمایی برای توابع هموار است. در بخش تجربی این پایان‌نامه، از یک حل‌گر طیفی فوریه برای تولید داده‌های مرجع دقیق معادله برگرز استفاده شده است.

جدول ۲-۱ مقایسه‌ای اجمالی از ویژگی‌های این روش‌ها را نشان می‌دهد. تمامی روش‌های کلاسیک به تولید شبکه محاسباتی وابسته‌اند و در ابعاد بالا ($d \geq 3$) با پدیده نفرین ابعاد^۹ و رشد نمایی هزینه‌های محاسباتی روبه‌رو می‌گردند.

۳-۲ شبکه‌های عصبی مصنوعی

شبکه عصبی مصنوعی^{۱۰} مدلی ریاضی و محاسباتی است که از پردازش اطلاعات در شبکه‌های بیولوژیکی الهام گرفته شده است. واحد بنیادی پردازش، نورون مصنوعی است که حاصل جمع وزن‌دار ورودی‌ها را با یک بایاس جمع نموده و آن را از یک تابع غیرخطی به نام تابع فعال‌ساز^{۱۱} عبور می‌دهد:


$$y = \sigma \left(\sum_{i=1}^n w_i x_i + b \right) \quad (۵-۲)$$

^۸Spectral Methods

^۹Curse of Dimensionality

^{۱۰}Artificial Neural Network (ANN)

^{۱۱}Activation Function



شکل ۲-۱: ساختار شماییک یک شبکه عصبی پرسپترون چندلایه با دو متغیر ورودی، دو لایه پنهان و یک خروجی اسکالر

جدول ۲-۲: توابع فعال‌ساز متداول در شبکه‌های عصبی عمیق

عنوان تابع	فرمول ریاضی	ویژگی رفتاری
سیگموئید (Sigmoid)	$\sigma(z) = \frac{1}{1 + e^{-z}}$	بازه خروجی $(0, 1)$ ، هموار و مشتق‌پذیر
تانژانت هیپربولیک (Tanh)	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	بازه خروجی $(-1, 1)$ ، هموار، متقارن حول مبدأ
واحد خطی یکسوشده (ReLU)	$\text{ReLU}(z) = \max(0, z)$	محاسبه سریع، نامشتق‌پذیر در صفر، مشتق دوم صفر

که در آن x_i ورودی‌ها، w_i وزن‌های سیناپسی، b پارامتر بایاس و $\sigma(\cdot)$ تابع فعال‌ساز است. چیدمان لایه‌ای این واحدها، ساختار پرسپترون چندلایه^{۱۲} را پدید می‌آورد. تبدیل برداری در لایه l به صورت رابطه بازگشتی زیر تعریف می‌شود:

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad (۲-۶)$$

که در آن $\mathbf{h}^{(0)} = \mathbf{x}$ بردار ورودی، $\mathbf{W}^{(l)}$ ماتریس وزن‌ها و $\mathbf{b}^{(l)}$ بردار بایاس لایه l ام است. ساختار گرافیکی یک پرسپترون چندلایه در شکل ۲-۱ نمایش داده شده است. انتخاب تابع فعال‌ساز مناسب نقشی تعیین‌کننده در رفتار و قابلیت مشتق‌پذیری شبکه دارد. جدول ۲-۲ توابع متداول را مقایسه می‌نماید. در شبکه‌های آگاه از فیزیک، به‌کارگیری توابع بی‌نهایت‌بار مشتق‌پذیر و هموار نظیر تانژانت هیپربولیک ($\tanh$) ضروری است، زیرا تشکیل جملات دیفرانسیلی نیازمند محاسبه مشتقات مرتبه دوم یا بالاتر است، در حالی که توابعی نظیر ReLU دارای مشتق دوم همه‌جا صفر هستند. پایه‌های نظری توانمندی شبکه‌های عصبی در تقریب توابع با «قضیه تقریب عمومی» استوار شده است. بر اساس قضیه اثبات‌شده توسط سیپینکو [۹]:

¹²Multi-Layer Perceptron (MLP)

قضیه ۱-۲ (تقریب عمومی سینکو). فرض کنید $\sigma(\cdot)$ یک تابع پیوسته سیگموئیدی (غیرخطی و کراندار) باشد. در این صورت، هر تابع پیوسته $f \in C(K)$ تعریف شده روی یک مجموعه فشرده $K \subset \mathbb{R}^n$ را می‌توان با یک شبکه عصبی پیش‌خور تک‌لایه پنهان با دقت دلخواه $\epsilon > 0$ تقریب زد.

هرچند این قضیه کفایت تئوریک شبکه‌های تک‌لایه با پهنای نامتناهی را اثبات می‌کند، اما در عمل شبکه‌های عمیق‌تر (با لایه‌های متوالی) با تعداد پارامترهای بسیار کمتر، قابلیت یادگیری توابع پیچیده فیزیکی را فراهم می‌سازند.

۴-۲ آموزش شبکه‌های عصبی عمیق

فرایند آموزش شبکه عصبی به معنای یافتن مجموعه پارامترهای بهینه $\theta^* = \{W, b\}$ است به‌گونه‌ای که یک تابع هدف مشخص کمینه گردد. در مسائل رگرسیون پیوسته، معیار میانگین مربعات خطا^{۱۳} پرکاربردترین تابع هزینه است:

$$\text{MSE}(\theta) = \frac{1}{N} \sum_{i=1}^N (u_{\theta}(\mathbf{x}_i) - u_i)^2 \quad (۷-۲)$$

که در آن $u_{\theta}(\mathbf{x}_i)$ پیش‌بینی مدل برای ورودی $\mathbf{x}_i$ و مقدار هدف است. کمینه‌سازی تابع هزینه با الگوریتم‌های گرادیان کاهشی انجام می‌شود:

$$\theta_{k+1} = \theta_k - \eta \nabla_{\theta} \mathcal{L}(\theta_k) \quad (۸-۲)$$

که در آن $\eta > 0$ نرخ یادگیری^{۱۴} و $\nabla_{\theta} \mathcal{L}$ گرادیان تابع هزینه نسبت به بردار پارامترهاست. محاسبه کارآمد این گرادیان‌ها توسط الگوریتم پس‌انتشار خطا^{۱۵} صورت می‌گیرد که مبتنی بر قاعده زنجیره‌ای روی گراف محاسباتی است [۱۰]. در بهینه‌سازی شبکه‌های آگاه از فیزیک، ترکیب دو بهینه‌ساز زیر راهبردی استاندارد به شمار می‌رود:

بهینه‌ساز آدام (Adam). این بهینه‌ساز با محاسبه گشتاور اول و دوم متحرک

¹³Mean Squared Error (MSE)

¹⁴Learning Rate

¹⁵Backpropagation

گرادیان‌ها، نرخ یادگیری تطبیقی را برای هر پارامتر اعمال می‌کند [۱۲]:

$$\begin{aligned} m_k &= \beta_1 m_{k-1} + (1 - \beta_1) g_k \\ v_k &= \beta_2 v_{k-1} + (1 - \beta_2) g_k^2 \\ \hat{m}_k &= \frac{m_k}{1 - \beta_1^k}, \quad \hat{v}_k = \frac{v_k}{1 - \beta_2^k} \\ \theta_{k+1} &= \theta_k - \eta \frac{\hat{m}_k}{\sqrt{\hat{v}_k} + \epsilon} \end{aligned} \quad (9-2)$$

که در آن $g_k = \nabla_{\theta} \mathcal{L}(\theta_k)$ ، $\beta_1 = 0.9$ ، $\beta_2 = 0.999$ و $\epsilon = 10^{-8}$ مقادیر استاندارد هستند. عبارات $\hat{m}_k$ و $\hat{v}_k$ اصلاح‌کننده بایاس اولیه در گام‌های آغازین بهینه‌سازی می‌باشند. **بهینه‌ساز شبه‌نیوتنی ال-بی‌اف‌جی‌اس (L-BFGS)**. این روش شبه‌نیوتنی با تقریب ماتریس معکوس هشین بر پایه تغییرات گرادیان در گام‌های پیشین، همگرایی مرتبه دو و فوق‌خطی در نزدیکی نقاط کمینه ایجاد می‌کند [۱۳]. در آموزش شبکه‌های آگاه از فیزیک، معمولاً ابتدا چند هزار گام با آدام اجرا می‌شود تا بهینه‌سازی از نواحی ناملازم عبور کند، و سپس برای رسیدن به دقت‌های بالای مهندسی، آموزش با الگوریتم L-BFGS تکمیل می‌گردد.

علاوه بر بهینه‌ساز، مقداردهی اولیه وزن‌ها نقشی حیاتی در همگرایی دارد. در این پژوهش از روش مقداردهی گزایه^{۱۶} استفاده شده است که واریانس وزن‌های هر لایه را متناسب با تعداد نورون‌های ورودی و خروجی آن تنظیم می‌نماید [۱۴].

۵-۲ مشتق‌گیری خودکار

مشتق‌گیری خودکار^{۱۷} یکی از حیاتی‌ترین ارکان محاسباتی در علوم داده مدرن و به‌ویژه در چارچوب شبکه‌های عصبی آگاه از فیزیک است [۱۵]. برای درک اهمیت این روش، مقایسه آن با دو رهیافت کلاسیک محاسبه مشتق ضروری است:

۱. **مشتق‌گیری نمادین (Symbolic Differentiation)**: در این روش، با استفاده از جبر نمادین (نظیر نرم‌افزارهای متمتیکا یا کتابخانه سای‌پای)، فرمول بسته ریاضی مشتق تولید می‌شود. چالش بنیادین این روش در شبکه‌های عصبی عمیق، پدیده «تورم جبری عبارات»^{۱۸} است، به‌گونه‌ای که طول فرمول مشتق برای توابع تودرتوی عمیق به‌صورت نمایی رشد کرده و ارزیابی محاسباتی آن ناممکن

^{۱۶}Xavier Initialization

^{۱۷}Automatic Differentiation (AD)

^{۱۸}Expression Swell

می‌گردد.

۲. **مشتق‌گیری عددی (Numerical Differentiation):** در این روش، مشتق با فرمول‌های تفاضلی (مانند تفاضل مرکزی) تقریب زده می‌شود. این روش با دو خطای متعارض روبه‌روست: اگر طول گام h بزرگ انتخاب شود، خطای برش^{۱۹} زیاد خواهد بود، و اگر h بسیار کوچک انتخاب شود، خطای گردکردن ممیز شناور ماشین (Round-off Error) ناشی از تفریق دو عدد بسیار نزدیک، دقت را نابود می‌سازد. افزون بر این، محاسبه گرادیان یک تابع با d متغیر ورودی نیازمند $O(d)$ بار ارزیابی تابع است که در ابعاد بالا به شدت کند است.

۳. **مشتق‌گیری خودکار (Automatic Differentiation):** این روش نه نمادین است و نه عددی، بلکه مبتنی بر این واقعیت است که هر برنامه کامپیوتری پیچیده، در نهایت دنباله‌ای از اعمال جبری ساده $(+, -, \times, \div)$ و توابع مقدماتی $(\sin, \exp, \tanh)$ است. مشتق‌گیری خودکار با ساخت یک «گراف محاسباتی»^{۲۰} و اعمال نظام‌مند «قاعده زنجیره‌ای»^{۲۱} در زمان اجرای کد، مشتقات دقیق را تا حد دقت ممیز شناور ماشین و بدون خطای برش محاسبه می‌کند.

۲-۵-۱ حالت‌های مشتق‌گیری خودکار

مشتق‌گیری خودکار به دو حالت اصلی تقسیم می‌شود:

حالت مستقیم (Forward Mode): در این حالت، مشتقات جهت‌دار هم‌گام با اجرای مستقیم برنامه (از ورودی به سمت خروجی) ارزیابی می‌شوند:

$$\dot{v}_i = \sum_{j \in \text{Parents}(i)} \frac{\partial v_i}{\partial v_j} \dot{v}_j \quad (۲-۱۰)$$

که در آن $\dot{v}_i = \frac{\partial v_i}{\partial x_k}$ مشتق متغیر میانی v_i نسبت به یک ورودی مشخص x_k است. این حالت برای توابعی که تعداد ورودی‌های آن‌ها کم و تعداد خروجی‌هایشان زیاد است $(f: \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ با } n \ll m)$ بسیار کارآمد است.

حالت معکوس (Reverse Mode): در این حالت، ابتدا یک گذر مستقیم برای محاسبه و ذخیره مقادیر میانی انجام می‌شود. سپس یک گذر بازگشتی از خروجی به

^{۱۹}Truncation Error

^{۲۰}Computational Graph

^{۲۱}Chain Rule

سمت ورودی‌ها اجرا شده و حساسیت‌ها (Adjoint) محاسبه می‌گردند:

$$\bar{v}_j = \sum_{i \in \text{Children}(j)} \bar{v}_i \frac{\partial v_i}{\partial v_j} \quad (11-2)$$

که در آن $\bar{v}_j = \frac{\partial \mathcal{L}}{\partial v_j}$ حساسیت تابع هدف اسکالر نسبت به متغیر میانی v_j است. هزینه این روش مستقل از ابعاد ورودی است، بنابراین برای توابعی با خروجی اسکالر و میلیون‌ها پارامتر ورودی ($f: \mathbb{R}^n \rightarrow \mathbb{R}$ با $n \gg 1$) فوق‌العاده سریع است و زیربنای الگوریتم پس‌انتشار خطا را تشکیل می‌دهد.

۲-۵-۲ نقش دوگانه و اختصاصی مشتق‌گیری خودکار در PINN

در یادگیری عمیق استاندارد، مشتق‌گیری خودکار صرفاً در حالت معکوس برای محاسبه گرادیان تابع هزینه نسبت به وزن‌های شبکه ($\nabla_{\theta} \mathcal{L}$) جهت آموزش به کار می‌رود. اما در چارچوب شبکه‌های آگاه از فیزیک، مشتق‌گیری خودکار یک کارکرد دوگانه و انقلابی ایفا می‌کند:

۱. **مشتق‌گیری نسبت به پارامترهای شبکه (∇_{θ}):** محاسبه گرادیان هزینه کل جهت

به‌روزرسانی وزن‌ها و بایاس‌ها با الگوریتم‌های آدم و L-BFGS،

۲. **مشتق‌گیری نسبت به متغیرهای فیزیکی فضا-زمان ($\partial_t, \partial_x, \partial_{xx}$):** ارزیابی دقیق

مشتقات مکانی و زمانی خروجی شبکه (u) نسبت به مختصات ورودی فیزیکی

(t, x) .

این کارکرد دوم ویژگی منحصربه‌فرد PINN است، زیرا به مدل اجازه می‌دهد عملگر باقیمانده فیزیکی $f(t, x) = u_t + uu_x - \nu u_{xx}$ را در هر نقطه دلخواه از فضا-زمان به صورت کاملاً پیوسته و تحلیلی ارزیابی کند، بدون آن‌که نیازی به ایجاد شبکه محاسباتی، گسسته‌سازی فضا یا خطای تفاضل محدود وجود داشته باشد.

کتابخانه‌های نوین نظیر جکس (JAX) با ترکیب تبدیل‌های تابعی `jit` و `grad` (کامپایل در زمان اجرا)، امکان محاسبه کارآمد مشتقات مرتبه بالا را بر روی پردازنده‌ها فراهم ساخته و زیرساخت محاسباتی این پژوهش را محقق کرده‌اند.

۶-۲ پیشینه پژوهش

به‌کارگیری شبکه‌های عصبی در حل معادلات دیفرانسیل ریشه در پژوهش‌های دهه ۱۹۹۰ میلادی دارد. لاگاریس و همکارانش در سال ۱۹۹۸ نشان دادند که می‌توان جواب

معادلات دیفرانسیل معمولی و جزئی را با پرسپترون‌های چندلایه فرمول‌بندی کرد به‌طوری که شرایط مرزی به‌صورت ساختاری ارضا شده و باقیمانده معادله روی نقاط آزمون کمینه گردد [۲]. با این حال، محدودیت توان پردازشی و عدم وجود کتابخانه‌های مشتق‌گیری خودکار در آن برهه، توسعه این روش‌ها را متوقف ساخت.

با پیشرفت علوم داده، رویکردهای یادگیری فیزیک‌پایه مجدداً کانون توجه قرار گرفتند. در این راستا، مدل‌سازی مبتنی بر فرایندهای گاوسی^{۲۲} برای استنتاج عملگرهای خطی [۳] و معادلات غیرخطی از طریق خطی‌سازی موضعی [۴] پیشنهاد گردید. این روش‌ها توانایی ارائه برآورد عدم قطعیت را دارا بودند، اما به دلیل فرضیات گاوسی، قابلیت تعمیم آن‌ها به مسائل به‌شدت غیرخطی با محدودیت روبه‌رو بود.

در رویکردی موازی، کارپاتنه و همکارانش چارچوب «علم داده هدایت‌شده با نظریه»^{۲۳} را برای ادغام اصول علمی در مدل‌های یادگیری ماشین معرفی نمودند [۵]. همچنین روش‌های شناسایی سیستم‌های دینامیکی بر پایه تنک‌سازی نظیر SINDy توسط برانتون و همکاران توسعه یافت [۷]. این روش‌ها اگرچه در کشف معادلات حاکم موفق بودند، اما به پایگاه داده‌ای جامع از توابع کاندید و مشتق‌گیری عددی روی داده‌های نویزی وابسته بودند.

انتشار مقاله رئیسی، پردیکاریس و کارنیاداکیس در سال ۲۰۱۹ تحولی یکپارچه در این حوزه به وجود آورد [۱]. آن‌ها با ترکیب شبکه‌های عمیق و مشتق‌گیری خودکار، ساختاری عام برای حل معادلات دیفرانسیل ارائه دادند که نیازی به تولید شبکه محاسباتی، خطی‌سازی موضعی یا کتابخانه جملات کاندید ندارد. عمومیت این چارچوب و کارایی آن در مسائل متنوع دینامیک سیالات و فیزیک غیرخطی، موج گسترده‌ای از تحقیقات نظری و کاربردی را در قالب مقالات مروری جامع نظیر کومو و همکاران [۸] به همراه داشته است. پژوهش حاضر بر پایه همین چارچوب شکل گرفته و پیاده‌سازی، تحلیل و ارزیابی عملکرد آن را در حل مسئله مستقیم معادله غیرخطی برگرز دنبال می‌کند.

۷-۲ جمع‌بندی فصل

در این فصل، مبانی نظری مورد نیاز برای فهم و تحلیل شبکه‌های عصبی آگاه از فیزیک مرور شد: تعاریف و معادلات دیفرانسیل جزئی غیرخطی، روش‌های عددی کلاسیک و چالش‌های محاسباتی آن‌ها، مبانی ساختار و بهینه‌سازی شبکه‌های عصبی عمیق، مبانی مشتق‌گیری خودکار و تاریخچه تحولات یادگیری ماشین فیزیک‌پایه. در فصل

²²Gaussian Process

²³Theory-Guided Data Science

بعد، فرمول‌بندی ریاضی و الگوریتمی شبکه‌های آگاه از فیزیک به تفصیل تبیین خواهد شد.

فصل ۳

شبکه‌های عصبی آگاه از فیزیک


در این فصل، ساختار ریاضی و الگوریتمی چارچوب «شبکه‌های عصبی آگاه از فیزیک» (PINN) که متدولوژی اصلی این پژوهش را تشکیل می‌دهد، به تفصیل و به صورتی گام‌به‌گام و خودخوان تشریح می‌گردد. هدف این چارچوب، ایجاد پلی استوار میان قوانین پایه‌ای فیزیک و توانمندی تقریب‌زدن شبکه‌های عصبی عمیق است. در ادامه، ابتدا صورت‌بندی کلی مسئله و ایده محوری روش تبیین شده و سپس ساختار مدل زمان‌پیوسته برای حل مستقیم معادله غیرخطی برگرز معرفی می‌شود. پس از آن، مبانی مدل‌های زمان‌گسسته به‌طور اجمالی مرور شده و در پایان، ملاحظات تجربی و عملیاتی حاکم بر آموزش و بهینه‌سازی این مدل‌ها مورد بحث قرار می‌گیرد [۱].

۱-۳ صورت‌بندی کلی مسئله و ایده محوری

بسیاری از سیستم‌های دینامیکی در فیزیک و مهندسی توسط معادلات دیفرانسیل جزئی غیرخطی و وابسته به زمان توصیف می‌شوند. صورت عام یک معادله دیفرانسیل جزئی وابسته به زمان برای تابع متغیر حالت $u(t, \mathbf{x})$ را می‌توان به فرم زیر بیان کرد:

$$u_t + \mathcal{N}[u] = 0, \quad \mathbf{x} \in \Omega, \quad t \in [0, T] \quad (1-3)$$

که در آن $u(t, \mathbf{x})$ تابع مجهول حالت سیستم (نظیر سرعت سیال در معادله برگرز)، $u_t = \frac{\partial u}{\partial t}$ مشتق زمانی، $\mathcal{N}[\cdot]$ عملگر دیفرانسیلی غیرخطی شامل مشتقات مکانی و جملات همرفتی-پخشی، و $\Omega \subset \mathbb{R}^d$ دامنه مکانی پیوسته با مرز $\partial\Omega$ است. این رابطه بیانگر تعادل نیروها و قوانین بقای حاکم بر فیزیک سامانه در هر نقطه مکانی و در هر لحظه زمانی است.



شکل ۳-۱: نمودار بلوکی چارچوب شبکه عصبی آگاه از فیزیک: تفکیک خطای داده و خطای فیزیک، تجمیع در تابع هزینه کل و حلقه بهینه‌سازی پارامترها

در مسئله مستقیم (Forward Problem)، با در دست داشتن فرم کامل معادله دیفرانسیل، ضرایب فیزیکی مشخص (نظیر ضریب لزجت ν) و شرایط اولیه و مرزی معین، هدف محاسبه، تقریب و بازسازی پیوسته میدان پاسخ $u(t, x)$ در سراسر دامنه زمانی-مکانی است. در این چارچوب، شبکه عصبی نقش یک حل‌گر عددی بدون شبکه محاسباتی را ایفا می‌کند.

ایده محوری در شبکه‌های آگاه از فیزیک بر پایه تقریب تابع جواب $u(t, x)$ توسط یک شبکه عصبی عمیق $u_\theta(t, x)$ با بردار پارامترهای وزن و بایاس θ بنا شده است. بر این اساس، عملگر باقیمانده دیفرانسیلی فیزیک $f(t, x)$ به صورت زیر تعریف می‌گردد:

$$f(t, \mathbf{x}) := u_t + \mathcal{N}[u] \quad (۲-۳)$$

که در آن $u = u_\theta(t, x)$ خروجی شبکه عصبی است. ویژگی برجسته این چارچوب آن است که کلیه مشتقات جزئی ظاهرشده در f (نظیر u_t و مشتقات مکانی) با استفاده از مشتق‌گیری خودکار نسبت به ورودی‌های گراف محاسباتی ارزیابی می‌شوند. در نتیجه، $f(t, x)$ خود نمایانگر یک شبکه عصبی با پارامترهای مشترک θ است که اصطلاحاً «شبکه باقیمانده آگاه از فیزیک» نامیده می‌شود.

در صورتی که شبکه u_θ به جواب دقیق معادله میل کند، مقدار باقیمانده در تمامی نقاط دامنه به سمت صفر میل خواهد کرد ($f \rightarrow 0$). بنابراین، فرایند آموزش از طریق یک تابع هزینه ترکیبی که هم‌زمان خطای برازش داده‌های مرزی-اولیه (MSE_u) و خطای عدم ارضای معادله دیفرانسیل (MSE_f) را کمینه می‌سازد، هدایت می‌شود. شکل ۳-۱ ساختار این چارچوب یکپارچه و جریان تبادل اطلاعات میان شبکه پاسخ، مشتق‌گیری خودکار، شبکه باقیمانده و الگوریتم بهینه‌سازی را نشان می‌دهد.

۲-۳ مدل‌های زمان‌پیوسته برای مسئله مستقیم برگرز

در مدل‌های زمان‌پیوسته، متغیرهای فضا و زمان به صورت هم‌زمان به عنوان ورودی‌های پیوسته به شبکه عصبی تغذیه می‌شوند: $(t, x) \mapsto u_\theta(t, x)$. این ویژگی موجب می‌شود که شبکه به یک تقریب‌زننده پیوسته در تمام دامنه فضا-زمان بدل گردد. در این پایان‌نامه، مسئله مستقیم معادله برگرز با لزجت بر روی دامنه مکانی $x \in [-1, 1]$ و زمانی $t \in [0, 1]$ با شرط اولیه $u(0, x) = -\sin(\pi x)$ و شرایط مرزی همگن $u(t, -1) = u(t, 1) = 0$ در نظر گرفته می‌شود:

$$u_t + uu_x - \nu u_{xx} = 0 \quad (۳-۳)$$

که در آن $\nu = 0.01/\pi$ ضریب لزجت سینماتیکی است. عملگر باقیمانده فیزیکی این معادله با استفاده از مشتقات ارزیابی‌شده توسط مشتق‌گیری خودکار به صورت صریح زیر تشکیل می‌گردد:

$$f(t, x) := u_t + uu_x - \nu u_{xx} \quad (۴-۳)$$

پارامترهای مجهول شبکه θ با کمینه‌سازی تابع هزینه ترکیبی زیر بهینه‌سازی می‌شوند:

$$\mathcal{L}(\theta) = \text{MSE}_u(\theta) + \text{MSE}_f(\theta) \quad (۵-۳)$$

که در آن:

$$\begin{aligned} \text{MSE}_u(\theta) &= \frac{1}{N_u} \sum_{i=1}^{N_u} |u_\theta(t_u^i, x_u^i) - u^i|^2 \\ \text{MSE}_f(\theta) &= \frac{1}{N_f} \sum_{i=1}^{N_f} |f_\theta(t_f^i, x_f^i)|^2 \end{aligned} \quad (۶-۳)$$

در روابط فوق، مجموعه $\{t_u^i, x_u^i, u^i\}_{i=1}^{N_u}$ شامل نقاط داده روی شرایط مرزی و اولیه است که مقادیر دقیق متغیر حالت در آن‌ها مشخص است (N_u نقطه). مجموعه $\{t_f^i, x_f^i\}_{i=1}^{N_f}$ نمایانگر «نقاط هم‌مکانی»^۱، یعنی نقاطی در درون دامنه پیوسته زمانی-مکانی است که هیچ اندازه‌گیری تجربی از مقدار u در آن‌ها وجود ندارد و صرفاً ارضای ساختار معادله دیفرانسیل ($f \approx 0$) بر آن‌ها اعمال می‌گردد (N_f نقطه).

^۱Collocation Points

جمله MSE_f در حقیقت نقش یک منظم‌ساز فیزیکی قدرتمند را ایفا می‌کند که فضای فرضیات شبکه عصبی را به توابعی محدود می‌سازد که ساختار فیزیکی حاکم بر معادله برگرز را برآورده کنند. این ساختار به مدل اجازه می‌دهد با تعداد بسیار اندکی از داده‌های مرزی-اولیه، میدان پیوسته پاسخ را در سراسر دامنه بازسازی نماید.

۳-۳ مدل‌های زمان‌گسسته

در مسائلی که نیازمند پیشروی در بازه‌های زمانی بسیار طولانی یا دقت‌های زمانی فوق‌العاده بالا هستند، مدل‌های زمان‌پیوسته ممکن است با افزایش تعداد نقاط هم‌مکانی و دشواری بهینه‌سازی روبه‌رو شوند. برای رفع این چالش، فرمول‌بندی زمان‌گسسته با تلفیق طرح‌های گام‌زنی زمانی ضمنی از خانواده روش‌های رانگه-کوتا^۲ با مرحله میانی پیشنهاد شده است.

با اعمال صورت کلی یک روش رانگه-کوتای ضمنی به معادله دیفرانسیل (۱-۳)، روابط گام زمانی به صورت زیر نوشته می‌شوند:

$$\begin{aligned} u^{n+c_i} &= u^n - \Delta t \sum_{j=1}^q a_{ij} \mathcal{N}[u^{n+c_j}], \quad i = 1, \dots, q \\ u^{n+1} &= u^n - \Delta t \sum_{j=1}^q b_j \mathcal{N}[u^{n+c_j}] \end{aligned} \quad (۷-۳)$$

که در آن $\{a_{ij}, b_j, c_j\}$ ضرایب جدول بوچر^۳ طرح رانگه-کوتا هستند [۲۳]. در این مدل، خروجی شبکه عصبی شامل $q + 1$ مقدار است که متناظر با جواب در مراحل میانی $u^{n+c_1}, \dots, u^{n+c_q}$ و جواب گام بعدی u^{n+1} می‌باشد. تابع هزینه بر اساس تطابق این مقادیر با روابط (۷-۳) و داده‌های لحظات t^n و t^{n+1} شکل می‌گیرد.

مزیت عمده این رهیافت، پایداری ذاتی روش‌های ضمنی رانگه-کوتا (نظیر خانواده گاوس-لژاندر) است که امکان انتخاب گام‌های زمانی بزرگ (Δt) بدون نقض شرایط پایداری را فراهم می‌آورد. در این پژوهش، تمرکز پیاده‌سازی و ارزیابی تجربی بر مدل زمان‌پیوسته قرار دارد، اما مرور نظری مدل زمان‌گسسته برای تبیین جامع ساختارهای یادگیری فیزیک‌پایه حائز اهمیت است.

^۲Runge-Kutta Methods

^۳Butcher Tableau

جدول ۳-۱: مقایسه تطبیقی مدل‌های زمان‌پیوسته و زمان‌گسسته در چارچوب شبکه‌های آگاه از فیزیک

شاخص ساختاری	مدل زمان‌پیوسته	مدل زمان‌گسسته
ورودی شبکه	بردار پیوسته زمانی-مکانی (t, x)	متغیر مکانی x در یک مقطع زمانی
خروجی شبکه	مقدار اسکالر میدان $u(t, x)$	مقادیر مراحل میانی رانگه-کوتا u^{n+1} و u^n
داده‌های آموزشی	شرایط اولیه و مرزی در دامنه زمان	مقادیر حالت در دو لحظه گسسته t^n و t^{n+1}
مزیت شاخص	سادگی و یکپارچگی ساختار	پایداری در گام‌های زمانی بزرگ
وضعیت در این پژوهش	پیاده‌سازی و تحلیل کامل تجربی	تحلیل و بررسی نظری

۳-۴ ملاحظات عملی در پیاده‌سازی و آموزش

تجارب محاسباتی و مبانی تجربی حاکی از آن است که دستیابی به همگرایی مطلوب در حل مستقیم معادله برگرز با شبکه‌های آگاه از فیزیک مستلزم رعایت چند اصل کلیدی در طراحی ساختار و الگوریتم آموزش است:

معماری شبکه و توابع فعال‌ساز. در حل مسئله مستقیم برگرز، پرسپترون‌های چندلایه با عمق ۴ لایه و ۵۰ نورون در هر لایه با تابع فعال‌ساز تانژانت هیپربولیک ($\tanh$) تعادل بسیار مناسبی میان ظرفیت تقریب و سرعت بهینه‌سازی ایجاد می‌کنند. به‌کارگیری لایه‌های افت تصادفی (Dropout) در این شبکه‌ها غیرضروری است، زیرا قید فیزیکی باقیمانده به‌طور خودکار مانع بیش‌برازش می‌گردد.

راهبرد بهینه‌سازی ترکیبی. استفاده از الگوریتم دو مرحله‌ای شامل شروع با بهینه‌ساز آدام (جهت فرار از کمینه‌های محلی و کاهش سریع خطای اولیه) و سپس تغییر وضعیت به بهینه‌ساز شبه‌نیوتنی L-BFGS (جهت رسیدن به دقت‌های بالا و همگرایی مرتبه دو) پایداری استراتژی آموزشی است.

راهبرد نمونه‌برداری نقاط هم‌مکانی در لایه شوک. توزیع و تراکم نقاط هم‌مکانی در دامنه حل بر پایداری مدل اثرگذار است. با توجه به تشکیل جبهه تیز شوک در حوالی $x = 0$ در معادله برگرز، افزایش چگالی نقاط هم‌مکانی در این ناحیه از طریق نمونه‌برداری غیریکنواخت متمرکز، دقت تقریب را به میزان چشمگیری بهبود می‌بخشد.

جدول ۳-۱ مشخصات و تمایزات ساختاری مدل‌های زمان‌پیوسته و زمان‌گسسته را مقایسه می‌نماید.

۵-۳ جمع‌بندی فصل

در این فصل، ساختار ریاضی و متدولوژی شبکه‌های عصبی آگاه از فیزیک برای حل مسئله مستقیم تشریح شد: مکانیزم تعریف شبکه باقیمانده بر پایه مشتق‌گیری خودکار، طراحی تابع هزینه ترکیبی فیزیک-داده، فرمول‌بندی مدل زمان‌پیوسته برای مسئله مستقیم معادله برگرز و نکات عملی در آموزش شبکه. در فصل چهارم، پیاده‌سازی محاسباتی این چارچوب برای معادله برگرز یک‌بعدی، نتایج تجربی و مقایسه جامع با مقاله معتبر مرجع ارائه خواهد شد.

فصل ۴

پیاده‌سازی و ارزیابی نتایج

در این فصل، جزئیات محاسباتی و نتایج تجربی حاصل از پیاده‌سازی چارچوب شبکه‌های عصبی آگاه از فیزیک در حل مستقیم معادله غیرخطی برگرز ارائه می‌گردد. ابتدا بستر نرم‌افزاری و ابزارهای مورد استفاده معرفی شده و سپس حل‌گر مرجع طیفی توسعه‌یافته برای معادله غیرخطی برگرز تشریح و با آزمون‌های مستقل اعتبارسنجی می‌شود. در ادامه، نتایج حل مستقیم معادله با مدل زمان‌پیوسته، تاریخچه همگرایی بهینه‌سازی ترکیبی و توزیع مکانی-زمانی خطاها گزارش و تحلیل می‌گردند. در بخش پایانی فصل، ارزیابی تطبیقی جامعی میان یافته‌های این پژوهش و نتایج مقاله معتبر مرجع رئیسی و همکاران (۲۰۱۹) به همراه تحلیل نقاط قوت و محدودیت‌های روش ارائه می‌شود.

۴-۱ بستر محاسباتی و ابزارهای پیاده‌سازی

کلیه الگوریتم‌های محاسباتی این پژوهش با زبان برنامه‌نویسی پایتون نسخه ۱۱.۳ پیاده‌سازی شده‌اند. برای پیاده‌سازی ساختار شبکه عصبی، کامپایل توابع و انجام مشتق‌گیری خودکار، کتابخانه جکس^۱ به کار گرفته شده است [۲۵]. جکس امکان ترکیب تبدیل‌های تابعی نظیر مشتق‌گیری خودکار (grad)، برداری‌سازی خودکار (vmap) و کامپایل در زمان اجرا (jit) را بر بستر کامپایلر XLA فراهم می‌سازد. انجام محاسبات عددی و ماتریسی با استفاده از کتابخانه‌های نامپای و سای‌پای، و رسم نمودارها با کتابخانه متپلاتلیب صورت پذیرفته است. الگوریتم بهینه‌سازی ترکیبی شامل پیاده‌سازی مستقیم بهینه‌ساز آدام و استفاده از رابط الگوریتم بهینه‌سازی مقید L-BFGS-B در کتابخانه سای‌پای است.

تمامی مراحل آموزش و آزمایش‌های عددی بر روی واحد پردازش مرکزی (CPU) و

^۱JAX

با دقت ممیز شناور ۶۴ بیتی (Float64) اجرا شده‌اند تا امکان بازتولید دقیق نتایج بر روی تجهیزات استاندارد دانشگاهی فراهم باشد. به منظور تضمین تکرارپذیری، بذره‌ای تولید اعداد تصادفی ثابت نگاه داشته شده و کد کامل برنامه به همراه راهنمای اجرا در پیوست الف و پوشه اختصاصی code ارائه گردیده است.

۲-۴ حل‌گر مرجع طیفی و اعتبارسنجی آن

جهت ارزیابی مستقل و دقیق عملکرد شبکه آگاه از فیزیک، یک حل‌گر عددی مرجع مستقل برای معادله برگرز با لزجت $\nu = 0.01/\pi$ توسعه داده شد. در این حل‌گر، گسسته‌سازی مکانی با روش طیفی فوریه بر روی ۱۰۲۴ مود با اعمال قاعده پالایش دو-سوم برای حذف خطای هم‌پوشانی^۲ صورت گرفته است [۲۱]. گام‌زنی زمانی با استفاده از روش تفاضل زمانی نمایی رانگه-کوتای مرتبه چهار (ETDRK4) با طول گام زمانی $\Delta t = 0.001$ انجام می‌پذیرد که برای معادلات دارای جملات پخش سفت، پایداری فوق‌العاده‌ای ارائه می‌دهد [۲۲]. ماتریس پاسخ حاصل بر روی یک شبکه زمانی-مکانی با ابعاد 101×1024 ذخیره شده و به‌عنوان معیار حل دقیق در ارزیابی‌ها استفاده شده است.

صحت عملکرد حل‌گر مرجع با دو آزمون مستقل اثبات گردید:

۱. **آزمون همگرایی عددی:** با نصف کردن گام زمانی ($\Delta t = 0.0005$)، بیشینه تغییر

نسبی جواب در مرتبه 6.2×10^{-9} و با دو برابر کردن تفکیک مکانی ($N_x = 2048$)،

تغییر نسبی برابر 4.1×10^{-4} ثبت گردید که مؤید همگرایی مطلوب روش است.

۲. **آزمون مقایسه با جواب نیمه‌تحلیلی کول-هوپف:** جواب معادله با تبدیل تحلیلی

کول-هوپف [۱۹] از طریق انتگرال‌گیری عددی مستقیم با دقت بسیار بالا محاسبه

شد. بیشترین اختلاف در ۱۹ نقطه نمونه‌برداری در زمان نهایی $t = 1$ کمتر از


6×10^{-4} بوده و در نواحی دور از جبهه شوک به مرتبه 10^{-8} کاهش یافت. همچنین

مطابقت با بسط‌های تحلیلی سری فوریه [۲۰] نیز بررسی گردید.

این آزمون‌ها نشان می‌دهند که دقت حل مرجع چندین مرتبه بزرگی فراتر از دقت

هدف شبکه‌های عصبی بوده و مبنایی کاملاً قابل‌اعتماد برای ارزیابی خطاست.

²Aliasing Error



شکل ۱-۴: توزیع نقاط آموزشی در مسئله مستقیم معادله برگرز: نقاط داده اولیه و مرزی ($N_u = 200$) و نقاط هم‌مکانی باقیمانده ($N_f = 10000$)

۳-۴ حل مستقیم معادله برگرز

در مسئله مستقیم، هدف محاسبه جواب $u(t, x)$ در دامنه مکانی $x \in [-1, 1]$ و زمانی $t \in [0, 1]$ با شرط اولیه $u(0, x) = -\sin(\pi x)$ و شرایط مرزی همگن دیریکله $u(t, -1) = u(t, 1) = 0$ و ضریب لزجت $\nu = 0.01/\pi$ است. ساختار شبکه عصبی مورد استفاده، پرسپترون چندلایه با ۴ لایه پنهان، ۵۰ نورون در هر لایه و تابع فعال‌ساز $\tanh$ است که در مجموع شامل ۷۸۵۱ پارامتر قابل آموزش می‌باشد.


داده‌های آموزشی روی مرزها و شرط اولیه شامل ۲۰۰ نقطه ($N_u = 200$) شامل ۱۰۰ نقطه در $t = 0$ و ۱۰۰ نقطه روی مرزهای مکانی است. تعداد نقاط هم‌مکانی درون دامنه برابر ۱۰۰۰۰ نقطه ($N_f = 10000$) انتخاب شد که نیمی از آن‌ها به صورت تصادفی یکنواخت و نیمی دیگر با توزیع نرمال متمرکز حول خط $x = 0$ (ناحیه تشکیل جبهه شوک) نمونه‌برداری گردیدند. موقعیت نقاط آموزشی در شکل ۱-۴ و مشخصات ساختاری آموزش در جدول ۱-۴ خلاصه شده است.

فرایند آموزش طی دو مرحله متوالی اجرا گردید: ۶۰۰۰ گام با الگوریتم آدام با نرخ یادگیری 10^{-3} و سپس ادامه بهینه‌سازی با روش L-BFGS-B تا دستیابی به همگرایی. مقدار تابع هزینه نهایی در انتهای مرحله آدام برابر 5.85×10^{-3} و در پایان مرحله L-BFGS برابر 8.71×10^{-5} حاصل شد که در آن سهم مولفه خطای داده MSE_u برابر 2.35×10^{-5} و مولفه خطای باقیمانده فیزیک MSE_f برابر 6.36×10^{-5} بود. تاریخچه تغییرات تابع هزینه در شکل ۲-۴ رسم گردیده است.

ارزیابی شبکه آموزش‌دیده بر روی کل شبکه مرجع با ۱۰۳۴۲۴ نقطه (101×1024)

جدول ۴-۱: تنظیمات ساختاری و پارامترهای آموزش مدل زمان‌پیوسته در مسئله مستقیم

مشخصات انتخابی	مولفه ساختاری
۴ لایه پنهان، ۵۰ نورون در هر لایه، فعال‌ساز تانژانت هیپربولیک	معماری شبکه عصبی
۷۸۵۱ پارامتر وزن و بایاس	تعداد کل پارامترهای شبکه
۲۰۰ نقطه (۱۰۰ شرط اولیه و ۱۰۰ شرط مرزی)	نقاط داده اولیه و مرزی (N_u)
۱۰۰۰۰ نقطه (۵۰۰۰ یکنواخت و ۵۰۰۰ متمرکز در ناحیه شوک)	نقاط هم‌مکانی باقیمانده (N_f)
روش گزایه (گلوروت)	الگوریتم مقداردهی اولیه
۶۰۰۰ گام آدام ($\eta = 10^{-3}$) و سپس L-BFGS-B تا ۶۰۰۰ فراخوانی	راهبرد بهینه‌سازی
۶۴ بیتی (Float64)	دقت محاسباتی ممیز شناور




شکل ۴-۲: تاریخچه کاهش تابع هزینه در مسئله مستقیم: همگرایی مرحله اول با الگوریتم آدام و اصلاح نهایی با روش شبه‌نیوتنی L-BFGS


نشان‌دهنده دستیابی به خطای نسبی در نرم L_2 برابر 2.15×10^{-2} است:

$$\text{Relative } L_2 \text{ Error} = \frac{\|u_{\text{pred}} - u_{\text{ref}}\|_2}{\|u_{\text{ref}}\|_2} = 2.15 \times 10^{-2} \quad (1-4)$$

مقایسه پروفیل‌های زمانی پاسخ پیش‌بینی‌شده با حل مرجع در مقاطع $t = 0.25$ ، $t = 0.5$ و $t = 0.75$ در شکل ۴-۳ نمایش داده شده است. شکل ۴-۴ نقشه خطای قدرمطلق را در سراسر دامنه زمانی-مکانی نشان می‌دهد. این نمودار تبیین می‌کند که خطای تقریب در بخش اعظم دامنه ناچیز بوده و بیشینه آن در لایه باریک گرادیان تند شوک (حوالی $x = 0$ برای $t > 0.3$) متمرکز است.



شکل ۳-۴: مقایسه پروفیل‌های زمانی حل دقیق مرجع و پیش‌بینی شبکه آگاه از فیزیک در سه لحظه $t = 0.25, 0.5, 0.75$



شکل ۴-۴: نقشه توزیع خطای قدرمطلق $|u_{ref} - u_{PINN}|$ در دامنه زمانی-مکانی در مسئله مستقیم

۴-۴ ارزیابی مقایسه‌ای با مقاله مرجع

به‌منظور سنجش دقیق جایگاه و صحت نتایج به‌دست‌آمده، مقایسه‌ای تفصیلی میان پیاده‌سازی این پژوهش و نتایج ارائه‌شده در مقاله بنیادین رئیسی، پردیکاریس و کارنیاداکیس (۲۰۱۹) [۱] انجام گرفته است. جدول ۲-۴ مشخصات ساختاری، تنظیمات آموزش و شاخص‌های دقتی هر دو پیاده‌سازی را خلاصه می‌نماید.

بررسی نتایج مقایسه‌ای نکات مهم زیر را نشان می‌دهد:

۱. **عمق در برابر پهنای شبکه:** در مقاله مرجع از شبکه‌ای عمیق‌تر (۹ لایه پنهان) با پهنای کم (۲۰ نورون) استفاده شده است، در حالی که در پژوهش حاضر از معماری با ۴ لایه پنهان و ۵۰ نورون استفاده گردید. معماری‌های عمیق‌تر قابلیت بالاتری در تقریب نواحی با گرادیان‌های بسیار تیز و ناپیوستگی‌های موضعی دارند که دلیل اصلی تفاوت در مرتبه خطای نهایی است.

۲. **سقف تکرارهای بهینه‌سازی و سخت‌افزار:** در مقاله مرجع بهینه‌سازی L-BFGS

جدول ۴-۲: مقایسه تطبیقی مشخصات و نتایج حل مستقیم معادله برگرز با مقاله مرجع رئیسی و همکاران (۲۰۱۹)

شاخص مقایسه‌ای	رئیسی و همکاران [۱]	پژوهش حاضر
معماری شبکه عصبی	۹ لایه پنهان، ۲۰ نورون در هر لایه	۴ لایه پنهان، ۵۰ نورون در هر لایه
تعداد کل پارامترها	۳۰۲۱ پارامتر	۷۸۵۱ پارامتر
تعداد نقاط داده اولیه و مرزی (N_u)	۱۰۰ نقطه	۲۰۰ نقطه
تعداد نقاط هم‌مکانی (N_f)	۱۰۰۰۰ نقطه	۱۰۰۰۰ نقطه
توزیع نقاط هم‌مکانی	نمونه‌برداری ابرمکعب لاتین	۵۰٪ یکنواخت + ۵۰٪ متمرکز در شوک
بستر نرم‌افزاری	تنسورفلو ۱ (Tensor-Flow 1.x)	جکس پایتون (JAX) با کامپایلر XLA
الگوریتم بهینه‌سازی	آدام و سپس L-BFGS	آدام (۶۰۰۰ گام) و سپس L-BFGS-B
خطای نسبی در نرم L_2	6.7×10^{-4}	2.15×10^{-2}

با تعداد تکرارهای بسیار بالا بر روی پردازنده‌های گرافیکی تخصصی تا رسیدن به حد نهایی دقت اجرا شده است، در حالی که در پژوهش حاضر به‌منظور امکان اجرای روان بر روی پردازنده‌های مرکزی معمولی دانشگاهی، تعداد تکرارها کنترل شده است.

۳. **کیفیت بازسازی پروفیل شوک:** با وجود تفاوت عددی در خطای میانگین، همان‌طور که در شکل ۴-۳ مشاهده می‌شود، مدل پیاده‌سازی‌شده در این پژوهش موقعیت زمانی و مکانی جبهه شوک و شیب شدید آن را در مقاطع مختلف $t = 0.25, 0.50, 0.75$ با وفاداری کیفی و کمی بسیار بالایی بازتولید نموده است.

۴-۵ بحث و تحلیل نتایج

تحلیل نتایج عددی حاصل از پیاده‌سازی، ابعاد علمی و مهندسی متعددی را در خصوص رفتار شبکه‌های آگاه از فیزیک در حل معادله برگرز روشن می‌سازد:

کارایی داده‌ای فوق‌العاده. در مسئله مستقیم، تقریب میدان پیوسته پاسخ بر روی بیش از یکصد هزار نقطه محاسباتی تنها بر مبنای ۲۰۰ نقطه داده اولیه و مرزی صورت پذیرفت. این نسبت حاکی از آن است که قید باقیمانده فیزیکی ($f \approx 0$) به عنوان یک قید هندسی-فیزیکی قدرتمند، فضای فرضیات شبکه را محدود کرده و از بیش‌برازش به

طور کامل جلوگیری می‌کند.

چالش لایه‌های با گرادیان تند. نقشه خطای شکل ۴-۴ نشان می‌دهد که تمرکز عمده خطا در حوالی خط $x = 0$ برای $t > 0.3$ رخ داده است. این پدیده مؤید آن است که تغییرات ناگهانی و نوک‌تیز در متغیر حالت، اصلی‌ترین چالش تقریب برای توابع فعال‌ساز هموار است. راهبرد نمونه‌برداری متمرکز در ناحیه شوک نقش موثری در مهار این خطا ایفا نمود.

مقایسه عملکرد با حل‌گرهای کلاسیک. حل‌گرهای کلاسیک نظیر روش‌های طیفی برای مسائل مستقیم استاندارد با شرایط مرزی ساده، از نظر سرعت اجرا و دقت برتری دارند، اما نیازمند شبکه‌بندی دامنه هستند. در نقطه مقابل، چارچوب شبکه آگاه از فیزیک بدون نیاز به تولید شبکه محاسباتی و مستقل از پیچیدگی‌های گسسته‌سازی، جواب پیوسته‌ای ارائه می‌دهد که در هر نقطه دلخواه زمانی و مکانی بدون نیاز به درونیابی قابل ارزیابی است.

محدودیت‌های پژوهش حاضر. تمرکز این پژوهش بر حل مسئله مستقیم معادله برگرز یک‌بعدی با مدل زمان پیوسته بوده است. گسترش به معادلات دوبعدی و سه‌بعدی و بررسی توابع فعال‌ساز تطبیقی از جمله مسائلی است که می‌تواند دقت تقریب را بیش از پیش بهبود بخشد.

۴-۶ جمع‌بندی فصل

در این فصل، پیاده‌سازی محاسباتی مدل زمان پیوسته شبکه آگاه از فیزیک برای حل مستقیم معادله غیرخطی برگرز تشریح شد. حل‌گر مرجع طیفی با دقت بالا توسعه یافته و با جواب نیمه‌تحلیلی کول-هوپف اعتبارسنجی گردید. نتایج نشان داد که مدل زمان پیوسته با ۲۰۰ نقطه داده اولیه-مرزی و ۱۰۰۰۰ نقطه هم‌مکانی به خطای نسبی 2.15×10^{-2} در بازسازی کل میدان پاسخ دست یافته و با موفقیت پدیده تشکیل موج شوک را بازتولید می‌نماید. همچنین ارزیابی مقایسه‌ای با مقاله مرجع رئیسی و همکاران (۲۰۱۹) کارایی و قابلیت‌های این رهیافت را مورد تایید قرار داد.

فصل ۵

نتیجه‌گیری و پیشنهادها

در این فصل، ابتدا خلاصه‌ای جامع از فرایند پژوهش و اقدامات انجام‌شده ارائه می‌گردد. سپس دستاوردها و یافته‌های کلیدی پژوهش تبیین شده و در پایان، پیشنهادهایی هدفمند برای ادامه و گسترش این پژوهش در مطالعات آتی ارائه می‌شود.

۵-۱ خلاصه پژوهش

در این پایان‌نامه، چارچوب «شبکه‌های عصبی آگاه از فیزیک» (PINN) به‌عنوان رویکردی نوین برای حل مسئله مستقیم معادله دیفرانسیل جزئی غیرخطی برگرز مورد بررسی نظری، پیاده‌سازی الگوریتمی و ارزیابی تجربی قرار گرفت.

در بخش نظری، پس از مرور اصول معادلات دیفرانسیل جزئی، روش‌های عددی کلاسیک (تفاضل محدود، اجزای محدود و روش‌های طیفی) و محدودیت‌های آن‌ها در ابعاد بالا، مبانی یادگیری عمیق و سازوکار مشتق‌گیری خودکار تشریح شد. سپس ساختار ریاضی شبکه باقیمانده، نحوه تشکیل تابع هزینه ترکیبی و فرمول‌بندی مدل زمان‌پیوسته تبیین گردید.

در بخش عملی و محاسباتی، مدل زمان‌پیوسته برای معادله غیرخطی برگرز یک‌بعدی با شرایط اولیه سینوسی و مرزهای همگن با استفاده از زبان برنامه‌نویسی پایتون و کتابخانه جکس پیاده‌سازی شد. به‌منظور ارزیابی دقیق نتایج، یک حل‌گر مرجع طیفی مستقل بر پایه روش فوریه و گام‌زنی نمایی مرتبه چهار (ETDRK4) توسعه یافت و صحت عملکرد آن با تبدیل نیمه‌تحلیلی کول-هوپف اثبات گردید. آزمایش‌های عددی حل مستقیم با ۲۰۰ نقطه مرزی-اولیه و ۱۰۰۰۰ نقطه هم‌مکانی با راهبرد بهینه‌سازی ترکیبی دو مرحله‌ای آدام و L-BFGS به اجرا درآمد و نتایج به دست آمده با مقاله مرجع رئیسی و همکاران (۲۰۱۹) مورد ارزیابی تطبیقی قرار گرفت.

۲-۵ یافته‌ها و دستاوردهای کلیدی

مهم‌ترین یافته‌ها و دستاوردهای این پژوهش را می‌توان در محورهای زیر خلاصه نمود:

۱. **کارایی داده‌ای چشمگیر در حل مسئله مستقیم:** مدل زمان‌پیوسته توانست با بهره‌گیری از تنها ۲۰۰ نقطه داده اولیه و مرزی، میدان پاسخ پیوسته معادله برگرز را بر روی کل دامنه با بیش از ۱۰۰ هزار نقطه بازسازی نموده و به خطای نسبی 2.15×10^{-2} در نرم L_2 نسبت به حل مرجع دست یابد. این امر مؤید آن است که افزودن قید باقیمانده فیزیکی به تابع هزینه، وابستگی به کلان‌داده‌های آموزشی را برطرف می‌سازد.
 ۲. **ردیابی دقیق دینامیک موج شوک:** مقایسه مقاطع زمانی در لحظات $t = 0.25, 0.50, 0.75$ نشان داد که شبکه عصبی آگاه از فیزیک رفتار فیزیکی تیز شدن پروفیل سرعت و تشکیل موج شوک را با وفاداری بالایی بازتولید می‌نماید.
 ۳. **تمرکز مکانی خطا در لایه‌های با گرادیان تند:** توزیع مکانی خطای مطلق نشان داد که بیشینه خطا در لایه بسیار باریک پیرامون جبهه شوک متمرکز است. اعمال راهبرد نمونه‌برداری غیریکنواخت و متمرکز در این ناحیه، عاملی تعیین‌کننده در مهار خطا و بهبود دقت تقریب بود.
 ۴. **اثربخشی راهبرد بهینه‌سازی ترکیبی:** تلفیق الگوریتم آدام (جهت فرار سریع از کمینه‌های محلی آغازین) و بهینه‌ساز شبه‌نیوتنی L-BFGS (جهت همگرایی دقیق و عمیق) نقشی حیاتی در رسیدن به دقت‌های مطلوب مهندسی ایفا نمود.
 ۵. **بازتولیدپذیری با سخت‌افزار استاندارد:** نتایج نشان داد که با استفاده از کتابخانه جکس و دقت ممیز شناور ۶۴ بیتی، امکان بازتولید کیفی و کمی رفتارهای روش‌های فیزیک‌پایه بر روی پردازنده‌های مرکزی استاندارد دانشگاهی بدون نیاز به تجهیزات پردازش فوق‌سریع میسر است.
- به‌طور کلی، شبکه‌های آگاه از فیزیک ابزاری قدرتمند و بدون نیاز به شبکه محاسباتی برای حل معادلات غیرخطی هستند و قابلیت ارائه تقریب پیوسته در سراسر فضا-زمان را بدون محدودیت‌های گسسته‌سازی سنتی فراهم می‌سازند.

۳-۵ پیشنهادها برای پژوهش‌های آینده

به‌منظور ادامه و تعمیق این مسیر پژوهشی، محورهای زیر پیشنهاد می‌گردد:

۱. **پیاده‌سازی مدل‌های زمان‌گسسته:** پیاده‌سازی و مقایسه کارایی الگوریتم‌های رانگه-کوتای ضمنی با مراحل بالا ($q > 100$) در مقایسه با مدل زمان‌پیوسته در بازه‌های زمانی طولانی.
۲. **توسعه به ابعاد بالاتر و معادلات پیچیده‌تر:** بررسی کارایی روش در حل معادلات برگرز دوبعدی و معادلات ناویه‌استوکس و ارزیابی مقیاس‌پذیری الگوریتم در هندسه‌های غیرمنظم.
۳. **روش‌های وزن‌دهی تطبیقی توابع هزینه:** به‌کارگیری راهبردهای وزن‌دهی پویا و گرادیان‌محور برای تنظیم توازن میان مولفه داده (MSE_u) و مولفه فیزیک (MSE_f) در طول آموزش.
۴. **نمونه‌برداری تطبیقی نقاط هم‌مکانی:** توسعه الگوریتم‌های نمونه‌برداری پویا بر اساس گرادیان یا باقیمانده معادله، جهت متمرکزسازی خودکار نقاط هم‌مکانی در نواحی ناپایداری و شوک.
۵. **به‌کارگیری توابع فعال‌ساز تطبیقی:** بررسی تاثیر توابع فعال‌ساز با پارامترهای شیب متغیر (Adaptive Activation Functions) جهت بهبود سرعت تقریب جبهه‌های تیز شوک.

فهرست منابع

- [1] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.
- [2] I. E. Lagaris, A. Likas, and D. I. Fotiadis, “Artificial neural networks for solving ordinary and partial differential equations,” *IEEE Transactions on Neural Networks*, vol. 9, no. 5, pp. 987–1000, 1998.
- [3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Machine learning of linear differential equations using Gaussian processes,” *Journal of Computational Physics*, vol. 348, pp. 683–693, 2017.
- [4] M. Raissi and G. E. Karniadakis, “Hidden physics models: Machine learning of nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 357, pp. 125–141, 2018.
- [5] A. Karpatne, G. Atluri, J. Faghmous, M. Steinbach, A. Banerjee, A. Ganguly, S. Shekhar, N. Samatova, and V. Kumar, “Theory-guided data science: A new paradigm for scientific discovery from data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 29, no. 10, pp. 2318–2331, 2017.
- [6] M. Schmidt and H. Lipson, “Distilling free-form natural laws from experimental data,” *Science*, vol. 324, pp. 81–85, 2009.
- [7] S. L. Brunton, J. L. Proctor, and J. N. Kutz, “Discovering governing equations from data by sparse identification of nonlinear dynamical systems,” *Proceedings of the National Academy of Sciences*, vol. 113, no. 15, pp. 3932–3937, 2016.
- [8] S. Cuomo, V. S. Di Cola, F. Giampaolo, G. Rozza, M. Raissi, and F. Piccialli, “Scientific machine learning through physics-informed neural networks: Where we are and what’s next,” *Journal of Scientific Computing*, vol. 92, article 88, 2022.
- [9] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals and Systems*, vol. 2, no. 4, pp. 303–314, 1989.

- [10] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, pp. 533–536, 1986.
- [11] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [12] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.
- [13] D. C. Liu and J. Nocedal, “On the limited memory BFGS method for large scale optimization,” *Mathematical Programming*, vol. 45, pp. 503–528, 1989.
- [14] X. Glorot and Y. Bengio, “Understanding the difficulty of training deep feedforward neural networks,” in *Proceedings of AIS-TATS*, pp. 249–256, 2010.
- [15] A. G. Baydin, B. A. Pearlmutter, A. A. Radul, and J. M. Siskind, “Automatic differentiation in machine learning: A survey,” *Journal of Machine Learning Research*, vol. 18, pp. 1–43, 2018.
- [16] R. J. LeVeque, *Finite Difference Methods for Ordinary and Partial Differential Equations*. SIAM, 2007.
- [17] O. C. Zienkiewicz, R. L. Taylor, and J. Z. Zhu, *The Finite Element Method: Its Basis and Fundamentals*, 6th ed. Elsevier Butterworth-Heinemann, 2005.
- [18] L. C. Evans, *Partial Differential Equations*, 2nd ed. American Mathematical Society, 2010.
- [19] E. Hopf, “The partial differential equation $u_t + uu_x = \mu u_{xx}$,” *Communications on Pure and Applied Mathematics*, vol. 3, pp. 201–230, 1950.
- [20] E. R. Benton and G. W. Platzman, “A table of solutions of the one-dimensional Burgers equation,” *Quarterly of Applied Mathematics*, vol. 30, pp. 195–212, 1972.
- [21] L. N. Trefethen, *Spectral Methods in MATLAB*. SIAM, 2000.
- [22] A.-K. Kassam and L. N. Trefethen, “Fourth-order time-stepping for stiff PDEs,” *SIAM Journal on Scientific Computing*, vol. 26, no. 4, pp. 1214–1233, 2005.
- [23] J. C. Butcher, *Numerical Methods for Ordinary Differential Equations*, 3rd ed. Wiley, 2016.
- [24] M. Abadi et al., “TensorFlow: Large-scale machine learning on heterogeneous systems,” in *Proceedings of OSDI*, 2016.
- [25] J. Bradbury et al., “JAX: Composable transformations of Python+NumPy programs,” 2018. [Online]. Available: github.com/google/jax

واژه‌نامه

واژه‌نامه فارسی به انگلیسی

معادل انگلیسی	واژه فارسی
Overfitting	بیش‌برازش
Backpropagation	پس‌انتشار
Activation Function	تابع فعال‌ساز
Loss Function	تابع هزینه
Initial Condition	شرط اولیه
Boundary Condition	شرط مرزی
Physics-Informed Neural Network	شبکه عصبی آگاه از فیزیک
Automatic Differentiation	مشتق‌گیری خودکار
Forward Problem	مسئله مستقیم
Partial Differential Equation	معادله دیفرانسیل جزئی
Ordinary Differential Equation	معادله دیفرانسیل معمولی
Mean Squared Error	میانگین مربعات خطا
Learning Rate	نرخ یادگیری
Curse of Dimensionality	نفرین ابعاد
Collocation Points	نقاط هم‌مکانی

واژه‌نامه انگلیسی به فارسی

واژه فارسی	معادل انگلیسی
تابع فعال‌ساز	Activation Function
مشتق‌گیری خودکار	Automatic Differentiation
پس‌انتشار	Backpropagation
شرط مرزی	Boundary Condition
نقاط هم‌مکانی	Collocation Points
نفرین ابعاد	Curse of Dimensionality
مسئله مستقیم	Forward Problem
شرط اولیه	Initial Condition
نرخ یادگیری	Learning Rate
تابع هزینه	Loss Function
میانگین مربعات خطا	Mean Squared Error
معادله دیفرانسیل معمولی	Ordinary Differential Equation
بیش‌برازش	Overfitting
معادله دیفرانسیل جزئی	Partial Differential Equation
شبکه عصبی آگاه از فیزیک	Physics-Informed Neural Network

پیوست الف: کد پیاده‌سازی محاسباتی

در این پیوست، متن کامل اسکریپت پیاده‌سازی پایتون بخش عملی پایان‌نامه بر بستر کتابخانه جکس (JAX) آورده شده است. این پیاده‌سازی شامل دو بخش بنیادین است:

۱. حل‌گر مرجع طیفی فوریه با گام‌زنی نمایی مرتبه چهار (ETDRK4) برای تولید داده‌های دقیق اعتبارسنجی و مقایسه،

۲. مدل زمان‌پیوسته شبکه عصبی آگاه از فیزیک برای حل مستقیم معادله غیرخطی برگرز به همراه الگوریتم بهینه‌سازی ترکیبی آدام و L-BFGS.

نسخه اجرایی این کد و کلیه داده‌ها در پوشه اختصاصی code در دسترس است.

```
1 #!/usr/bin/env python3
2 # -*- coding: utf-8 -*-
3 """
4 Physics-Informed Neural Network (PINN) for the 1D Burgers equation.
5
6 Reproduction (for B.Sc. thesis) of the continuous-time results of:
7 Raissi, Perdikaris, Karniadakis, "Physics-informed neural networks...",
8 J. Comput. Phys. 378 (2019) 686-707. (Appendix A1. and B(1.
9
10 Two modes:
11 forward : data-driven solution of Burgers (learn u(t,x) from IC/BC + PDE residual)
12 inverse : data-driven discovery of Burgers (learn lambda1, lambda2 from scattered data)
13
14 Burgers equation:  $u_t + \lambda_1 u * u - \lambda_2 u_{xx} = 0$ 
15  $x \in [-1, 1]$ ,  $t \in [0, 1]$ ,  $\lambda_1 = 0.1$ ,  $\lambda_2 = /01.0\pi$  (forward)
16  $u(0, x) = -\sin(\pi x)$ ,  $u(t, -1) = u(t, 1) = 0$ 
17
18 Reference solution: Fourier spectral in space (N=512, 2/3 de-aliasing) + RK4 in time.
19
20 Requirements: jax[cpu], numpy, scipy, matplotlib
21 Output: metrics JSON + figures written to ../figs/
22 """
23 import argparse
24 import json
25 import os
26 import time
27
28 import numpy as np
29
30 import jax
31 from jax import grad, jit, vmap
32 from jax.tree_util import tree_map
33 from jax.flatten_util import ravel_pytree
34 import jax.numpy as jnp
35 from jax import random
36
37 try:
38     jax.config.update("jax_enable_x64", True)
39 except Exception: # very old jax
40     from jax import config as _cfg
```

```

111 _cfg.update("jax_enable_x64", True)
112
113 import matplotlib
114 matplotlib.use("Agg")
115 import matplotlib.pyplot as plt
116
117 HERE = os.path.dirname(os.path.abspath(__file__))
118 FIGDIR = os.path.join(os.path.dirname(HERE), "figs")
119 os.makedirs(FIGDIR, exist_ok=True)
120
121 PI = float(np.pi)
122 NU = 01.0 / PI # viscosity used in the paper
123
124 # -----
125 # Reference spectral solver (independent of the neural network)
126 # -----
127 def burgers_reference(nx=1024, dt001.0=, t_out=None, nu=NU):
128     """Solve Burgers with Fourier spectral + ETD RK4 (Kassam & Trefethen 2005).
129
130     The diffusion term is treated exactly in Fourier space, so the scheme
131     stays stable for the stiff thin shock layer. Returns t, x, U[nt, nx].
132     """
133     L = 0.2
134     x = np.linspace(0.1-, 0.1, nx, endpoint=False)
135     k = 0.2 * PI * np.fft.fftfreq(nx, d=L / nx)
136     dealias = (np.abs(k) < (nx // 3) * 0.2) * PI / L).astype(float)
137
138     # ETD RK4 coefficients via contour integral (M points on unit circle)
139     M = 32
140     r = np.exp(1j * PI * (np.arange(1, M + 1) - (5.0 / M)
141     Lv = -nu * k ** 2
142     LR = dt * Lv[:, None] + r[None, :]
143     E = np.exp(dt * Lv)
144     E2 = np.exp(dt * Lv / (0.2
145     Q = dt * np.real(np.mean((np.exp(LR / (0.2 - (0.1 / LR, axis=1))
146     f1 = dt * np.real(np.mean(
147         (0.4- - LR + np.exp(LR) * 0.4) - 0.3 * LR + LR ** 2)) / LR ** 3, axis=1))
148     f2 = dt * np.real(np.mean(
149         0.2 * 0.2) + LR + np.exp(LR) * (0.2- + LR)) / LR ** 3, axis=1))
150     f3 = dt * np.real(np.mean(
151         (0.4- - 0.3 * LR - LR ** 2 + np.exp(LR) * 0.4) - LR)) / LR ** 3, axis=1))
152
153     def nlin(uu):
154         uh = np.fft.fft(uu)
155         ux = np.real(np.fft.ifft(1j * k * uh))
156         return np.fft.fft(-uu * ux) * dealias
157
158     u = -np.sin(PI * x)
159     v = np.fft.fft(u)
160     if t_out is None:
161         t_out = np.linspace(0, 0.1, 101)
162     U = [u.copy()]
163     t = 0.0
164     for target in t_out[1:]:
165         nsteps = int(round((target - t) / dt))
166         for _ in range(nsteps):
167             Nv = nlin(np.real(np.fft.ifft(v)))
168             a = E2 * v + Q * Nv
169             Na = nlin(np.real(np.fft.ifft(a)))
170             b = E2 * v + Q * Na
171             Nb = nlin(np.real(np.fft.ifft(b)))
172             c = E2 * a + Q * 0.2) * Nb - Nv
173             Nc = nlin(np.real(np.fft.ifft(c)))
174             v = E * v + f1 * Nv + f2 * (Na + Nb) + f3 * Nc
175             t += dt
176             U.append(np.real(np.fft.ifft(v)))
177     U = np.array(U)
178     assert np.all(np.isfinite(U)), "reference solver diverged!"
179     return t_out, x, U
180
181 # -----

```

```

114 # MLP + derivatives (automatic differentiation)
115 # -----
116 def init_mlp(key, layers):
117     keys = random.split(key, len(layers) - 1)
118     params = []
119     for kk, (din, dout) in zip(keys, zip(layers[:-1], layers[1:])):
120         W = random.normal(kk, (din, dout)) * np.sqrt(0.2) / (din + dout)
121         b = jnp.zeros((dout,))
122         params.append((W, b))
123     return params
124
125
126 def u_point(params, t, x):
127     h = jnp.stack([t, x])
128     for W, b in params[:-1]:
129         h = jnp.tanh(jnp.dot(h, W) + b)
130     W, b = params[-1]
131     return jnp.dot(h, W)[0] + b[0]
132
133
134 _u_t = grad(u_point, argnums=1)
135 _u_x = grad(u_point, argnums=2)
136 _u_xx = grad(grad(u_point, argnums=2), argnums=2)
137
138 u_pred = jit(vmap(u_point, in_axes=(None, 0, 0)))
139 u_t_pred = jit(vmap(_u_t, in_axes=(None, 0, 0)))
140 u_x_pred = jit(vmap(_u_x, in_axes=(None, 0, 0)))
141 u_xx_pred = jit(vmap(_u_xx, in_axes=(None, 0, 0)))
142
143
144 # -----
145 # Manual Adam (no extra dependencies, works with any jax version)
146 # -----
147 def adam(loss_grad_fn, params, iters, lr=1e-3, log_every=500, tag="adam"):
148     m = tree_map(jnp.zeros_like, params)
149     v = tree_map(jnp.zeros_like, params)
150     b1, b2, eps = 9.0, 999.0, 1e-8
151     hist = []
152     for it in range(1, iters + 1):
153         loss, g = loss_grad_fn(params)
154         m = tree_map(lambda mm, gg: b1 * mm + (1 - b1) * gg, m, g)
155         v = tree_map(lambda vv, gg: b2 * vv + (1 - b2) * (gg ** 2), v, g)
156         mh = tree_map(lambda mm: mm / (1 - b1 ** it), m)
157         vh = tree_map(lambda vv: vv / (1 - b2 ** it), v)
158         params = tree_map(lambda p, mm, vv: p - lr * mm / (jnp.sqrt(vv) + eps),
159                           params, mh, vh)
160         hist.append(float(loss))
161         if it % log_every == 0 or it == 1:
162             print(f"[{tag}] iter {it:5d}/{iters} loss = {float(loss):6.2e}", flush=True)
163     return params, hist
164
165
166 def lbfgs(loss_fn, grad_fn, params, maxfun=2000):
167     from scipy.optimize import minimize
168     x0, unravel = ravel_pytree(params)
169     x0 = np.asarray(x0, dtype=np.float64)
170
171     def fun(x):
172         return float(loss_fn(unravel(jnp.asarray(x))))
173
174     def jac(x):
175         g = grad_fn(unravel(jnp.asarray(x)))
176         flat, _ = ravel_pytree(g)
177         return np.asarray(flat, dtype=np.float64)
178
179     state = {"n": 0, "hist": []}
180
181     def cb(x):
182         state["n"] += 1
183         if state["n"] % 200 == 0:
184             print(f"[lbfgs] eval {state['n']} loss = {fun(x):6.2e}", flush=True)
185
186     t0 = time.time()

```

```

187 res = minimize(fun, x0, jac=jac, method="L-BFGS-B",
188               callback=cb,
189               options={"maxfun": maxfun, "maxiter": maxfun,
190                       "ftol": 1e-12, "gtol": 1e-10})
191 print(f"[lbfgs] done: {res.message} fun={res.fun6.:e} "
192       f"nit={res.nit} nfev={res.nfev} time={time.time()-t01.:f}s", flush=True)
193 return unravel(jnp.asarray(res.x, dtype=jnp.float64)), float(res.fun)
194
195 # -----
196 # Forward problem
197 # -----
198
199 def run_forward(adam_iters=6000, lbfgs_maxfun=6000, seed=0):
200     rng = np.random.RandomState(seed)
201     print("== forward: solving reference ==", flush=True)
202     t_g, x_g, Uref = burgers_reference()
203     print(f" reference grid: t={t_g.shape}, x={x_g.shape}, "
204           f"|u|_max at t=1: {np.abs(Uref[-1]).max():f}", flush=True)
205
206     # Training data: Nu points on initial + boundary
207     Nu0, Nub = 100, 100
208     x0 = rng.uniform(-1, 1, Nu0)
209     t0 = np.zeros_like(x0)
210     u0 = -np.sin(PI * x0)
211     tb = rng.uniform(0, 1, Nub)
212     xb = rng.choice([0.1-, [0.1, size=Nub])
213     ub = np.zeros_like(tb)
214     t_u = np.concatenate([t0, tb])
215     x_u = np.concatenate([x0, xb])
216     u_u = np.concatenate([u0, ub])
217
218     # Collocation points: half uniform + half clustered around the shock (x=0),
219     # where the solution develops a steep front for t > .3.0~
220     Nf1, Nf2 = 5000, 5000
221     t_f1 = rng.uniform(0, 1, Nf1)
222     x_f1 = rng.uniform(-1, 1, Nf1)
223     t_f2 = rng.uniform(0, 1, Nf2)
224     x_f2 = np.clip(rng.normal(0.0), 2.0, Nf2), 0.1-, (0.1
225     t_f = np.concatenate([t_f1, t_f2])
226     x_f = np.concatenate([x_f1, x_f2])
227     Nf = Nf1 + Nf2
228
229     t_u_ = jnp.asarray(t_u); x_u_ = jnp.asarray(x_u); u_u_ = jnp.asarray(u_u)
230     t_f_ = jnp.asarray(t_f); x_f_ = jnp.asarray(x_f)
231
232     layers = [2, 50, 50, 50, 50, 1]
233     params = init_mlp(random.PRNGKey(seed), layers)
234     npar = sum(w.size + b.size for w, b in params)
235     print(f"== forward: network {layers} params={npar} "
236           f"N_u={len(t_u)} N_f={Nf} ==", flush=True)
237
238     @jit
239     def loss_fn(p):
240         mse_u = jnp.mean((u_pred(p, t_u_, x_u_) - u_u_) ** 2)
241         uu = u_pred(p, t_f_, x_f_)
242         f = (u_t_pred(p, t_f_, x_f_) + uu * u_x_pred(p, t_f_, x_f_)
243              - NU * u_xx_pred(p, t_f_, x_f_))
244         mse_f = jnp.mean(f ** 2)
245         return mse_u + mse_f
246
247     @jit
248     def grad_fn(p):
249         return grad(loss_fn)(p)
250
251     def loss_grad(p):
252         return loss_fn(p), grad_fn(p)
253
254     print(f"[forward] initial loss = {float(loss_fn(params))6.:e}", flush=True)
255     t_start = time.time()
256     params, hist_adam = adam(loss_grad, params, adam_iters, lr=1e-3,
257                             log_every=500, tag="forward/adam")
258     params, loss_lbfgs = lbfgs(loss_fn, grad_fn, params, maxfun=lbfgs_maxfun)
259     print(f"[forward] total time = {time.time()-t_start1.:f}s", flush=True)

```

```

۲۶۰ mse_u_fin = float(jnp.mean((u_pred(params, t_u_, x_u_) - u_u_) ** 2))
۲۶۱ _uu = u_pred(params, t_f_, x_f_)
۲۶۲ _ff = (u_t_pred(params, t_f_, x_f_) + _uu * u_x_pred(params, t_f_, x_f_)
۲۶۳         - NU * u_xx_pred(params, t_f_, x_f_))
۲۶۴ mse_f_fin = float(jnp.mean(_ff ** 2))
۲۶۵ print(f"[forward] final MSE_u = {mse_u_fin6.:e}, MSE_f = {mse_f_fin6.:e}",
۲۶۶         flush=True)
۲۶۷
۲۶۸ # Evaluate on the full reference grid
۲۶۹ TT, XX = np.meshgrid(t_g, x_g, indexing="ij")
۲۷۰ Up = np.asarray(u_pred(params, jnp.asarray(TT.ravel()),
۲۷۱                     jnp.asarray(XX.ravel()))).reshape(TT.shape)
۲۷۲ err = np.linalg.norm(Up - Uref) / np.linalg.norm(Uref)
۲۷۳ print(f"[forward] relative L2 error = {err6.:e}", flush=True)
۲۷۴
۲۷۵ metrics = {
۲۷۶     "mode": "forward",
۲۷۷     "layers": layers, "n_params": int(npar),
۲۷۸     "Nu": int(len(t_u)), "Nf": int(Nf),
۲۷۹     "adam_iters": adam_iters, "lbfgs_maxfun": lbfgs_maxfun,
۲۸۰     "loss_adam_final": hist_adam[-1], "loss_lbfgs_final": loss_lbfgs,
۲۸۱     "mse_u_final": mse_u_fin, "mse_f_final": mse_f_fin,
۲۸۲     "rel_l2": float(err), "seed": seed,
۲۸۳     "nu": NU,
۲۸۴ }
۲۸۵ with open(os.path.join(FIGDIR, "forward_metrics.json"), "w") as f:
۲۸۶     json.dump(metrics, f, indent=2)
۲۸۷ np.savez(os.path.join(FIGDIR, "forward_data.npz"),
۲۸۸         t=t_g, x=x_g, Uref=Uref, Upred=Up,
۲۸۹         hist_adam=np.array(hist_adam),
۲۹۰         t_u=t_u, x_u=x_u)
۲۹۱
۲۹۲ # --- figures ---
۲۹۳ plt.rcParams.update({"font.size": 11})
۲۹۴ # 1) snapshots
۲۹۵ fig, axes = plt.subplots(1, 3, figsize=5.10), (2.3, sharey=True)
۲۹۶ for ax, tc in zip(axes, 25.0], 5.0, ([75.0:
۲۹۷     i = int(np.argmax(np.abs(t_g - tc)))
۲۹۸     ax.plot(x_g, Uref[i], "k-", lw6.1, label="Exact")
۲۹۹     ax.plot(x_g, Up[i], "r--", lw3.1, label="PINN")
۳۰۰     ax.set_title(f"t = {t_g[i2.:f]}")
۳۰۱     ax.set_xlabel("x")
۳۰۲     ax.grid(alpha(3.0=
۳۰۳ axes[0].set_ylabel("u(t, x)")
۳۰۴ axes[0].legend(frameon=True)
۳۰۵ fig.suptitle("Burgers equation: exact vs PINN (forward problem)")
۳۰۶ fig.tight_layout()
۳۰۷ fig.savefig(os.path.join(FIGDIR, "burgers_snapshots.pdf"))
۳۰۸ plt.close(fig)
۳۰۹
۳۱۰ # 2) loss history (raw curve + running minimum, as Adam is spiky)
۳۱۱ fig, ax = plt.subplots(figsize=5.6), (8.3)
۳۱۲ hist_adam = np.asarray(hist_adam)
۳۱۳ runmin = np.minimum.accumulate(hist_adam)
۳۱۴ ax.semilogy(hist_adam, color="lightsteelblue", lw8.0, label="Adam (raw)")
۳۱۵ ax.semilogy(runmin, "b-", lw4.1, label="Adam (running min)")
۳۱۶ ax.axhline(loss_lbfgs, color="r", ls="--", lw2.1, label="L-BFGS (final)")
۳۱۷ ax.set_xlabel("Adam iteration")
۳۱۸ ax.set_ylabel("Loss (MSE_u + MSE_f)")
۳۱۹ ax.set_title("Training loss history (forward problem)")
۳۲۰ ax.grid(alpha3.0=, which="both")
۳۲۱ ax.legend()
۳۲۲ fig.tight_layout()
۳۲۳ fig.savefig(os.path.join(FIGDIR, "loss_history.pdf"))
۳۲۴ plt.close(fig)
۳۲۵
۳۲۶ # 3) error heatmap
۳۲۷ fig, ax = plt.subplots(figsize=5.6), (8.3)
۳۲۸ im = ax.imshow(np.abs(Up - Uref), origin="lower", aspect="auto",
۳۲۹                 extent=[x_g[0], x_g[-1], t_g[0], t_g[-1]], cmap="hot")
۳۳۰ ax.set_xlabel("x")
۳۳۱ ax.set_ylabel("t")
۳۳۲ ax.set_title("Absolute error |u_exact - u_pinn| (forward problem)")

```

```

fig.colorbar(im, ax=ax, label="|error|")
fig.tight_layout()
fig.savefig(os.path.join(FIGDIR, "error_heatmap.pdf"))
plt.close(fig)

# 4) training points
fig, ax = plt.subplots(figsize=(6.3, 6.3))
ax.scatter(t_f[:5], x_f[:5], s=3, c="lightsteelblue", label="Collocation (subset)")
ax.scatter(t_u, x_u, s=14, c="red", marker="x", label="IC/BC data")
ax.set_xlabel("t")
ax.set_ylabel("x")
ax.set_title("Training points (forward problem)")
ax.legend()
fig.tight_layout()
fig.savefig(os.path.join(FIGDIR, "forward_points.pdf"))
plt.close(fig)
print("[forward] figures saved.", flush=True)
return metrics

# -----
# Inverse problem (discovery of lambda1, lambda2)
# -----
def run_inverse(n_data=5000, noise=0.0, adam_iters=6000, lbfgs_maxfun=6000,
               seed=1):
    rng = np.random.RandomState(seed)
    print(f"== inverse: n={n_data}, noise={noise} ==", flush=True)
    t_g, x_g, Uref = burgers_reference()
    # scattered observations: half uniform + half clustered around the shock,
    # where the u_xx term (hence lambda2) actually matters.
    n1, n2 = n_data // 2, n_data - n_data // 2
    ti = np.concatenate([rng.uniform(0, 1, n1), rng.uniform(0, 1, n2)])
    xi = np.concatenate([rng.uniform(-1, 1, n1),
                        np.clip(rng.normal(0.0), 2.0, n2), 0.1-, (0.1)]
    ii = np.clip((ti * (len(t_g) - 1)).astype(int), 0, len(t_g) - 1)
    jj = np.clip((xi + 1) / 2 * (len(x_g))).astype(int), 0, len(x_g) - 1)
    ui = Uref[ii, jj].copy()
    if noise > 0:
        ui = ui + noise * np.std(ui) * rng.randn(n_data)

    t_d = jnp.asarray(ti); x_d = jnp.asarray(xi); u_d = jnp.asarray(ui)

    layers = [2, 30, 30, 30, 30, 30, 1]
    params = init_mlp(random.PRNGKey(seed), layers)
    lam = jnp.array(0.0), ([0.0 # lambda1, lambda2 to be identified
    npar = sum(w.size + b.size for w, b in params) + 2
    print(f"== inverse: network {layers} params={npar} ==", flush=True)

    @jit
    def loss_fn(pl):
        p, l = pl
        mse_u = jnp.mean((u_pred(p, t_d, x_d) - u_d) ** 2)
        uu = u_pred(p, t_d, x_d)
        f = (u_t_pred(p, t_d, x_d) + l[0] * uu * u_x_pred(p, t_d, x_d)
            - l[1] * u_xx_pred(p, t_d, x_d))
        return mse_u + jnp.mean(f ** 2)

    @jit
    def grad_fn(pl):
        return grad(loss_fn)(pl)

    def loss_grad(pl):
        return loss_fn(pl), grad_fn(pl)

    print(f"[inverse] initial loss = {float(loss_fn((params, lam)))6.:e}", flush=True)
    t_start = time.time()
    (params, lam), hist_adam = adam(loss_grad, (params, lam), adam_iters,
                                   lr=1e-3, log_every=500, tag="inverse/adam")
    (params, lam), loss_lbfgs = lbfgs(loss_fn, grad_fn, (params, lam),
                                       maxfun=lbfgs_maxfun)
    print(f"[inverse] total time = {time.time()-t_start1.:f}s", flush=True)

    lam = np.asarray(lam, dtype=float)

```

```

406 true = np.array(0.1]), NU])
407 pct = 0.100 * np.abs(lam - true) / np.abs(true)
408 print(f"[inverse] identified lambda = {lam}, true = {true}", flush=True)
409 print(f"[inverse] percentage errors = {pct}%", flush=True)
410
411 metrics = {
412     "mode": "inverse", "layers": layers, "n_params": int(npar),
413     "n_data": n_data, "noise": noise,
414     "adam_iters": adam_iters, "lbfgs_maxfun": lbfgs_maxfun,
415     "loss_adam_final": float(hist_adam[-1]),
416     "loss_lbfgs_final": float(loss_lbfgs),
417     "lambda_identified": [float(lam[0]), float(lam[1])],
418     "lambda_true": 0.1, NU],
419     "pct_error": [float(pct[0]), float(pct[1])],
420     "seed": seed,
421 }
422 tag = f"inverse_metrics_noise{int(100*noise)}.json"
423 with open(os.path.join(FIGDIR, tag), "w") as f:
424     json.dump(metrics, f, indent=2)
425
426 # scatter figure (only for the clean case to keep the thesis light)
427 if noise == :0.0
428     fig, ax = plt.subplots(figsize=(2.6, 8.3))
429     sc = ax.scatter(ti, xi, s=6, c=ui, cmap="seismic", vmin=-1, vmax=1)
430     ax.set_xlabel("t")
431     ax.set_ylabel("x")
432     ax.set_title(f"Scattered training data (inverse problem, N={n_data})")
433     fig.colorbar(sc, ax=ax, label="u(t, x)")
434     fig.tight_layout()
435     fig.savefig(os.path.join(FIGDIR, "inverse_points.pdf"))
436     plt.close(fig)
437 return metrics
438
439
440 def main():
441     ap = argparse.ArgumentParser()
442     ap.add_argument("--mode", choices=["forward", "inverse", "all"],
443                     default="all")
444     ap.add_argument("--adam-iters", type=int, default=6000)
445     ap.add_argument("--lbfgs-maxfun", type=int, default=6000)
446     args = ap.parse_args()
447
448     all_metrics = {}
449     if args.mode in ("forward", "all"):
450         all_metrics["forward"] = run_forward(
451             adam_iters=args.adam_iters, lbfgs_maxfun=args.lbfgs_maxfun)
452     if args.mode in ("inverse", "all"):
453         all_metrics["inverse_clean"] = run_inverse(
454             noise0.0, adam_iters=args.adam_iters,
455             lbfgs_maxfun=args.lbfgs_maxfun)
456         all_metrics["inverse_noisy"] = run_inverse(
457             noise01.0, adam_iters=args.adam_iters,
458             lbfgs_maxfun=args.lbfgs_maxfun, seed=2)
459     with open(os.path.join(FIGDIR, "metrics_all.json"), "w") as f:
460         json.dump(all_metrics, f, indent=2, default=str)
461     print("ALL DONE. metrics:", json.dumps(all_metrics, indent=2, default=str),
462           flush=True)
463
464
465 if __name__ == "__main__":
466     main()

```

فرم ارزیابی پایان نامه کارشناسی

نام و نام خانوادگی دانشجو	محمد امیر بابازاد
شماره دانشجویی	۱۴۰۲۱۳۵۱۰۴
رشته تحصیلی	علوم کامپیوتر
عنوان پایان نامه	حل مسئله مستقیم معادله غیرخطی برگرز با استفاده از شبکه های عصبی آگاه از فیزیک
استاد راهنما	دکتر بابک آذرنوید
تاریخ دفاع	
نمره به عدد	
نمره به حروف	
نام و امضای استاد راهنما	
نام و امضای داور	
نام و امضای مدیر گروه	

Abstract

The numerical solution of nonlinear partial differential equations (PDEs), particularly the viscous Burgers equation characterized by steep shock gradients, represents a fundamental challenge in scientific computing and fluid dynamics. While classical numerical methods are mathematically rigorous, they inherently rely on computational mesh generation and suffer from exponential complexity in higher dimensions. On the other hand, purely data-driven deep learning models require vast amounts of labeled training data and fail to ensure physical consistency in sparse-data regimes. The physics-informed neural network (PINN) paradigm addresses these limitations by embedding governing differential laws directly into the loss function of deep neural networks. This thesis presents a comprehensive theoretical study, computational implementation, and empirical evaluation of continuous-time PINNs for solving the forward problem of the one-dimensional nonlinear Burgers equation, benchmarked against authoritative literature.

First, the theoretical foundations spanning partial differential equations, classical numerical methods, deep feedforward networks, optimization algorithms, and automatic differentiation are established. Next, the continuous-time PINN formulation is constructed for the nonlinear Burgers equation using automatic differentiation to evaluate physical differential residuals. In the computational section, the continuous-time model is implemented in Python using the JAX library and trained via a two-stage optimization strategy combining the Adam optimizer and the quasi-Newton L-BFGS method. An independent high-precision reference solver based on the Fourier spectral method with fourth-order exponential time-differencing (ETDRK4) is developed and verified against the semi-analytical Cole-Hopf transformation.

The empirical results and extensive comparative analysis with the seminal benchmark of Raissi et al. (2019) demonstrate that the physics-informed neural network accurately reconstructs the continuous spatio-temporal solution field using only a small set of boundary and initial points alongside collocation points. The model effectively captures the sharp shock front dynamics while eliminating the need for computational mesh generation, highlighting the high data efficiency and robust approximation capability of physics-informed architectures for nonlinear dynamical systems.

Keywords: Physics-Informed Neural Networks, Nonlinear Burgers Equation, Forward Problem, Automatic Differentiation, Fourier Spectral Method, Scientific Computing.



University of Bonab
Faculty of Basic Sciences
Department of Mathematics and Computer Science

B.Sc. Thesis in Computer Science

**Solving the Forward Problem of the Nonlinear Burgers
Equation Using Physics-Informed Neural Networks**

Supervisor:
Dr. Babak Azarnavid

By:
Mohammad Amir Babazad
Student ID: 1402135104

September 2026